

# Vizualizace sémantické sítě

edison

1. května 2017

# Obsah

<b>I</b>	<b>K sémantickým sítím</b>	<b>3</b>
<b>1</b>	<b>Princetonský WordNet</b>	<b>5</b>
1.1	Motivace vzniku . . . . .	5
1.1.1	Strojově čitelné slovníky . . . . .	6
1.1.2	Od slovníků k WordNetu . . . . .	7
1.2	K vlivu psycholingvistiky na organizaci WordNetu . . . . .	8
1.3	Organizace WordNetu . . . . .	9
1.3.1	Synsety a vztahy mezi nimi . . . . .	9
1.4	Sémantické vztahy WordNetu . . . . .	11
1.4.1	Hyperonymie a hyponymie . . . . .	11
1.4.2	Meronymie a holonymie . . . . .	12
1.5	Lexikální vztahy ve Wordnetu . . . . .	12
1.5.1	Synonymie . . . . .	12
1.5.2	Antonymie . . . . .	14
<b>2</b>	<b>Další wordnety</b>	<b>16</b>
2.1	EuroWordNet . . . . .	16
<b>II</b>	<b>Přehled a porovnání existujících vizualizací sémantických sítí</b>	<b>20</b>
<b>3</b>	<b>Metodologie porovnání</b>	<b>22</b>
3.1	Výběr rozhraní . . . . .	22
3.2	Strukturalizace přehledu a kritéria hodnocení . . . . .	23
3.3	Podmínky testování . . . . .	24
3.4	WordNet Search jako základ porovnání . . . . .	24
<b>4</b>	<b>Vizualizace s webovým rozhraním</b>	<b>27</b>
4.1	An interactive visualization of the Princeton WordNet database . . . . .	27
4.2	WordNET Editor . . . . .	28
4.3	Cornetto Demo . . . . .	29
4.4	WordVis . . . . .	32
4.5	sloWTool . . . . .	35

4.6	BabelNetXplorer . . . . .	37
<b>5</b>	<b>Vizualizace v aplikačním prostředí Java</b>	<b>40</b>
5.1	wmbrowser . . . . .	41
5.2	Treebolic . . . . .	42
5.3	VisualBrowser . . . . .	42
<b>6</b>	<b>Desktopové aplikace</b>	<b>44</b>
6.1	Artha . . . . .	44
6.2	GoldenDict . . . . .	46
<b>7</b>	<b>Shrnutí přehledu rozhraní a vyplývající závěry o vhodném rozhraní k sémantickým sítím</b>	<b>47</b>
<b>III</b>	<b>Praktická část: rozhraní k sémantické síti</b>	<b>49</b>
<b>8</b>	<b>Design rozhraní</b>	<b>50</b>
8.1	Textová prezentace . . . . .	50
8.2	Grafická prezentace . . . . .	50
<b>9</b>	<b>Použité technologie</b>	<b>51</b>
9.1	HTML . . . . .	51
9.2	CSS . . . . .	51
9.3	JavaScript . . . . .	51
9.4	JSON . . . . .	51
	<b>Bibliografie</b>	<b>54</b>

Část I

**K sémantickým sítím**

Sémantické sítě, neboli wordnety, jsou lexikální databáze vytvořené s rozličnými záměry, mezi něž patří například i strojová inference informací v počítačovém zpracování přirozeného jazyka. Ve wordnetu jsou slova slučována podle významů do synonymických okruhů a tyto okruhy propojovány sémantickými vztahy, čímž dostávají svému označení sémantické sítě.

# Kapitola 1

## Princetonský WordNet

Princetonský WordNet je prvním wordnet vůbec. Vznikal na univerzitě v Princetonu pod G. A. Millerem od poloviny 80. let 20. století. Vzhledem k tomu, že byl prvním wordnetem, bylo k němu referováno jako k WordNetu, bez přívlastku. Ačkoliv tento stav v podstatě přetrvává dodnes, oproti době jeho vzniku se situace změnila, vzniklo několik dalších wordnetů a nastala tudíž potřeba je rozlišit. V anglickém prostředí se obvykle pojmem wordnet míní ten princetonský a všechny ostatní wordnety mají přívlastek či vlastní jméno. Příkladem necht je Balkanet či Eurowordnet. Ačkoliv v mezinárodním prostředí je obvyklé přívlastek „princetonský“ používat, bude tato práce pracovat s následujícím rozlišením:

- *WordNet* (ve významu princetonský WordNet)
- *wordnet* (ve významu obecné sémantické sítě založené na WordNetu)
- konkrétní wordnety, např. *Balkanet*

### 1.1 Motivace vzniku

Od počátků snah o zpracování přirozeného jazyka (NLP, natural language processing) bylo nutné poskytnout programu data o lexiku ve zpracovávaném textu, ať už ona data byla jakákoliv. Kupříkladu pro překlad se mělo za to, že stačí ekvivalentní dvojice ve zdrojovém a cílovém jazyce, později se přidal kontext v případě statistického strojového překladu spolu s dalšími informacemi, jako je například slovní druh. Tradičně se lexikální materiál ukládá způsobem nikoliv diametrálně odlišným od papírových slovníků určených pro lidské uživatele. Ty obvykle obsahují seřazené jednotlivé záznamy s potřebnými informacemi o slovech, z nichž pak program může čerpat při zpracování textu.

Jak uvádí Pala; Ševeček [PŠ13], uspořádání lexikálního materiálu v formě, v jaké je v tradičních slovnících je sice vhodné pro člověka, jelikož je to v podstatě jediný způsob, jak lidskému uživateli umožnit vyhledání konkrétního slova, zvláště nezná-li jeho význam, pro strojové zpracování ale je slovník nedostatečný. Seřazení indexu slovních forem je sice pro efektivní vyhledávání slov důležité, struktura tradičního slovníku neposkytuje vhodně zakódované informace o příbuznosti slov. Jednak kvůli onomu abecednímu řazení

inherentně vzdaluje slova, jež člověk chápe jako nějakým způsobem blízka [PŠ13], jednak neobsahuje dodatečné vazby mezi příbuznými slovy (nebo je obsahuje ve formě nevhodné pro strojové zpracování). Významová blízkost může vyplývat ze vztahu volné synonymie, antonymie, podřazenosti, nadřazenosti, etc. Pokud si tedy například uživatel výkladového slovníku nepříliš obeznámený s daným jazykem vyhledá určité heslo, dozví se sice pravděpodobně jeho význam, ale nebude schopen své znalosti prohlubovat dále kupříkladu zjištěním, jaké slovo odpovídá opačnému významu.

Dalším všeobecným problémem při využití tradičních slovníků k počítačovému zpracování jazyka je fakt, že lexikografové předpokládají u uživatele slovníku značné encyklopedické znalosti. Zařazují tak do slovníku jen informace dle jejich názoru důležité pro zařazení dané entity do příslušné nadřazené třídy (genus proximum) a rozlišení dané entity v nadřazené třídě (differentia specifica). Vyhledá-li si tedy člověk ve Slovníku spisovného jazyka českého [kurva fix, si snad budu muset dojit do knihovny, abych to ocitoval] heslo vlk, zjistí následující:

**vlk:** psovitá šelma šedě (n. šedožlutě) zbarvená, žijící v Evropě, Asii a v Sev. Americe

Definice a priori předpokládá, že uživatel je obeznámen s tím, co je šelma a co je pes. Pokud takovou znalostí neslyne (což je vcelku představitelné například u cizince), je nucen si tato slova ve slovníku najít a podívat se na jejich definice (pomiňme nyní netriviální úkol převést slovo *psovitá* na základní tvar *pes*). Pokud nerozumí definicím ani nadřazených slov, musí pokračovat v hierarchii dále a dále.

Z uvedeného případu plyne, že jakkoliv je možné správným vyhledáváním hyperonym<sup>1</sup> dospět k tomu, že vlk je konkrétní entita našeho vesmíru, živá bytost o čtyřech končetinách, savec nějakým způsobem příbuzný se psovi, má šedou srst etc., je takový proces dosti komplikovaný. Příklad s cizincem se sice nemusí zdát zcela relevantní, protože se dá předpokládat, že daný člověk má, byť v jiném jazyce, stejné základní znalosti předpokládané lexikografy jako člověk, jehož mateřštinou je čeština. Situace je však dramaticky jiná u počítače (přesněji u počítačového programu). Na rozdíl od člověka totiž počítač nemá žádné předchozí znalosti, tudíž musí projít celým procesem popsáním výše, aby byl schopen kupříkladu určit, že vlk může umřít (ježto je živá bytost). Protože však tradiční slovníky typu SSJČ byly vytvářené pro papírové médium, neobsahují žádné propojení ve stylu *toto je odkaz na hyperonymum*, a počítač tudíž jen těžko může zjišťovat, na které vlastně slovo se to má podívat, aby se dobral podstaty pojmu vlk.

### 1.1.1 Strojově čitelné slovníky

V zájmu automatizace vyhledávání ve slovníku vznikaly tzv. strojově čitelné slovníky<sup>2</sup>, což je pojem souhrnně označující lexikální databáze. Podle množství informací, které taková databáze obsahuje, pak lze tyto dělit na slovníky, taxonomie a ontologie. Je evidentní, že obyčejný slovník neobsahuje oproti tradičnímu papírovému slovníku navíc žádné me-

<sup>1</sup>nadřazené slovo

<sup>2</sup>machine readable dictionary

tainformace, takže je počítač při jeho užívání v podstatě omezen na elektronický listovač [Mil+90].

Míru, jakou se strojově čitelný slovník odlišuje od pouhé zdigitalizované formy papírového slovníku a přiblíží se k pokročilé lexikální databázi, lze vyjádřit v několika stupních. V případě, že slovník má jednotlivé významy uspořádané v hierarchii dle nadřazenosti–podřazenosti, lze jej označit za taxonomii, tedy systém s hlubší strukturou než pouze abecedním řazením hesel.

Dalším stupněm je již komplexní lexikální databáze, která má jednotlivé významy propojeny rozličnými vztahy, počínaje onou základní hyperonymií a hyponymií a pokračuje kupříkladu vztahy meronymie<sup>3</sup> či antonymie<sup>4</sup>. Kromě vztahů mezi významy bude taková lexikální databáze obsahovat zřejmě i další informace, například o syntaktických kategoriích slov, definice jejich významů, etc. Databáze tak popsaných významů propojených sémantickými vztahy může být nazývána ontologií. [Gar]

### 1.1.2 Od slovníků k WordNetu

Výše uvedená opozice papírového slovníku a ontologie ilustruje rozdíly tradičního slovníku a počítačově zpracovatelné lexikální databáze. Jedním z klíčových rozdílů je propojenost jednotek v lexikální databázi – tradiční slovníky, byvše v době svého vzniku většinou určeny pro distribuci v papírové formě určené pro lidského uživatele, neobsahují důsledné propojení sémanticky souvisejících slov. Příkladem budiž *kostra* a její části, např. *lebka*. V SSČ<sup>5</sup> i SSJČ se u *lebky* uvádí, že jde o *kostru hlavy*. Lze tedy s jistotou rezervou tvrdit, že heslo obsahuje své holonymum<sup>6</sup>, opačný odkaz však již ani jeden z oněch dvou slovníků neobsahuje. Z celkem evidentních ekonomických důvodů nejsou u hesla *kostra* uvedeny všechny její části. Tento příklad příhodně ukazuje i jistou nesystémovost tradičních slovníků, která je pro počítačové zpracování fatální, jelikož, jak bylo zmíněno výše, znemožňuje systémové procházení hierarchie slovní zásoby a zjišťování podstaty jednotlivých významů.

Naznačeny tedy byly vlastnosti, jež by lexikální databáze měla oproti tradičnímu slovníku mít, aby byla použitelná pro počítačové zpracování přirozeného jazyka. Především jde o systémovost vztahů. Hypero-/hyponymie je vztah oboustranný, tudíž by mělo být možné se stejnou cestou dostat od nadřazeného slova k podřazenému a naopak. Dále je podstatné, aby sémantické vztahy mezi významy byly přesně definované, a tudíž algoritmy zpracovatelné. Jedině tak je totiž možno jednoznačně určit, které slovo (či slova) je v takové databázi konkrétnímu slovu nadřazené, které je jeho specifikací, označením jeho částí, etc.

S touto myšlenkou vznikl WordNet – lexikální síť provázaná sémantickými vztahy, která dle poznatků psycholingvistiky odráží uspořádání lexikálního materiálu v lidském mozku (více v kap. 1.2 na straně 8). [PŠ13]

<sup>3</sup>vztah *je částí*, tedy např. *dveře* je meronymem *trolejbusu*

<sup>4</sup>protikladu

<sup>5</sup>Slovník spisovné češtiny

<sup>6</sup>vztah opačný k meronymii; tedy např. *dům* je holonymem pro *okno*, *dveře*, *práh* etc.



## 1.2 K vlivu psycholingvistiky na organizaci WordNetu

Jelikož G. A. Miller, který byl koordinátorem projektu WordNet, byl svým zaměřením psycholog a přispěl k vzniku psycholingvistiky, ubíral se projekt Wordnetu podobným směrem. Společně s Johnson-Lairdem se Miller zaměřil na výzkum, jakým způsobem je lexikální materiál uložen v lidském mozku. Tento vědní směr je označován právě jako psycholingvistika a jeho počátky jsou spojeny s průzkumem asociací a modelem budování modelu mentálního slovníku člověka. Výchozí myšlenka, jež se odráží i ve způsobu organizace WordNetu, spočívá v tom, že slovní zásoba je konceptuálně (tedy že slova se stejným významem jsou seskupena u sebe) a pro některé slovní druhy (zejména substantiva) hierarchicky.

Jednou z otázek tohoto směru bylo, jakým způsobem je v hierarchickém modelu paměti řešeno získávání vlastností pro význam, které jsou „podděděné“ po významech hierarchicky výše umístěných. Aby člověk byl schopen například určit pravdivostní hodnotu výroku *Kanárek může létat*, musí použít svou dlouhodobou pamět. Její organizace je pak možná (minimálně) dvěma způsoby. První, redundantní, by vypadal tak, že by u každé podtřídy ptáků bylo uloženo, že její instance jsou schopny létat. Druhý, již na první pohled výrazně méně náročný na úložný prostor, by příznak schopnosti létat měl uložený pouze u třídy *pták*. Pro zjištění, zda kanárek létá, by pak bylo nutno zapojit inferenční proces ve stylu *kanárek je pták, tudíž může létat*. [CQ69]

Jak Collins; Quillian [CQ69] dále uvádí, lze předpokládat, že v případě prvního způsobu organizace paměti by člověk mohl kteroukoliv informaci o příznacích (vlastnostech) z paměti vyvolat za konstantní čas. Naproti tomu v případě způsobu druhého by extrakce příznaku z významu v hierarchii položeného výše měla trvat delší čas než extrakce příznaku přítomného přímo u významu, jenž je subjektem věty. Důvodem by měla být nutnost zapojení inferenčního procesu.

Pokus, kterým podpořili Collins; Quillian [CQ69] druhý, neredundantní, způsob ukládání příznaků v paměti, spočíval v tom, že testovací subjekty, dobrovolníci z řad zaměstnanců společnosti Bolt Beranek and Newman, měly určovat, zda je jim předložený výrok pravdivý, či nepravdivý. Měli tak činit co nejpřesněji a v co nejkratším čase, přičemž byla měřena rychlost jejich reakce. Ukázalo se, reakční doba při určování pravdivosti výroku *Kanárek umí létat*<sup>7</sup> je delší než při určování pravdivosti výroku *Kanárek umí zpívat*<sup>8</sup> a ještě delší při určování výroku *Kanárek má kůži*<sup>9</sup>. Důvodem pro tyto progresivní prodlevy podle nich právě byla zvětšující se vzdálenost od významu *kanárka* ke významu, u něhož byl uložen příslušný příznak, tedy *umí zpívat*, *umí létat*, resp. *má kůži*. Příznak *umí zpívat* totiž je pravděpodobně uložen přímo u *kanárka*, jelikož jej odlišuje od ostatních ptáků, zatímco příznak *umí létat* je obecným znakem ptáků, tudíž je uložen u významu *pták*. V poslední řadě pak příznak *má kůži* bude patrně uložen u významu *zvíře*, který je oněch tří v hierarchii nejvýše, a ze všech tudíž od významu *kanárek* nejdále.

WordNet se svou hierarchickou organizací substantiv a verb pravděpodobně konceptu-

<sup>7</sup>angl. A canary can fly

<sup>8</sup>angl. A canary can sing

<sup>9</sup>angl. A canary has skin

álně blíží organizaci lexika v lidské paměti.

## 1.3 Organizace WordNetu

Ve WordNetu lze nalézt informace autosémantikách, tedy substantivech, adjektivech, slovesech a příslovcích [Vos98]. Synsémantika (např. předložky, spojky etc.) nebyla zahrnuta, jelikož se zdá, že jsou uložena odděleně od slov plnovýznamových. Teorii, že jsou funkční slova uchovávána jako součást syntaktikonu, podpořil kupříkladu Garrett [Gar82] při svém pozorování afatických pacientů.

Vůbec první podnět k uvědomění, že různé slovní druhy podléhají různé strukturalizaci v paměti, vyvolal asociační test, který provedli Fillenbaum; Jones [FJ65]. Tomuto asociačnímu testu byli podrobeni anglicky mluvící subjekty, kteří měli za úkol uvést první slovo, které je napadne při myšlence na předložené slovo. Předkládána jim byla dobře známá a často používaná slova náležející k různým slovním druhům. Ukázalo se, že ve většině případů náleží asociované slovo ke stejnému slovnímu druhu jako slovo, které asociaci vyvolalo. Substantiva vyvolala asociaci na substantivum v 79 % případů, adjektiva v 65 % případů a slovesa v 43 % případů.

Ačkoliv není zřejmé, jak je znalost o slovním druhu určitého slova získávána, lze z uvedených dat předpokládat, že slovní druh je vskutku primární organizační vlastností lexikálního materiálu v lidském mozku a informace o něm je snadno dostupná (alespoň intuitivně). Jelikož správné tvoření vět vyžaduje alespoň intuitivní povědomí o tom, které slovo náleží ke které syntaktické kategorii, není s podivem, že tato informace je dostupná lidskému uvažování velmi jednoduše. Jelikož se však slova stejného slovního druhu příliš často nevyskytují pohromadě, není evidentní, jak tyto znalosti člověk získává. [FJ65; Mil<sup>+</sup>90]

### 1.3.1 Synsety a vztahy mezi nimi

Slova (slovní formy) jsou ve WordNetu seskupována podle svého významu a slovního druhu, k němuž náležejí. Takové řadě slov se v terminologii WordNetu říká synset (synonym set), neboli synonymická řada. Každý synset reprezentuje jeden význam, ale je nutno mít na paměti, že granularita synsetů nemusí být konsistentní a v podstatě záleží na tom, jak si tvůrci zadefinovali synonymum (více v kap. 1.5.1 na straně 12). Synset je ve WordNetu reperezentací významu a je definován slovy (formami), které obsahuje. Jelikož význam slov je definován tím, v jakém synsetu se vyskytují (ke kterému konceptu náleží), jde v podstatě o kruhovou definici, a tudíž je zřejmé, že definice významů musí být rozšířena. Lze říci, že význam konceptu reprezentovaného synsetem je založen na jeho pozici v celé struktuře. Význam konceptu je tedy definován jeho kontextem, to znamená nadřazenými a podřazenými koncepty. [KM02] Vztahy mezi koncepty jsou vztahy sémantické, jelikož se týkají významů slov (cf. lexikální vztahy níže).

Aby bylo možno WordNet použít k inferenčnímu vyvozování závěrů (získávání informací) o slovech strojově, jsou synsety ve WordNetu propojeny vztahy, z nichž je zřejmé, jakou informaci inferenční stroj získá, přejde-li po onom vztahu k dalšímu konceptu. Stro-

jové zpracování textu, potažmo strojová inference informací, se od té lidské liší v jednom zásadním aspektu, kterým je fakt, že stroj nemá k dispozici encyklopedické znalosti o světě, jež má k dispozici člověk. Pro strojové zpracování textu je tedy nutné zajistit, aby všechna potřebná data bylo možné získat z lexikální databáze, v tomto případě z WordNetu.

Zmíněné kritérium, že slovní formy jednoho synsetu musí náležet k jedné syntaktické kategorii (slovnímu druhu), je podloženo jednoduchým závěrem o nezaměnitelnosti slov přináležejících různým slovním druhům. Seskupování konceptů podle slovního druhu vede, zřejmě navzdory snaze o ekonomii ukládání informací, kterou se lidský mozek vyznačuje, k jisté redundantnosti systému. Existuje totiž mnoho slov (zvláště např. v angličtině), která zastupují jak substantivum, tak verbum (např. angl. *show*, popř. české *stát*). Míra sémantické podobnosti takových slov může být značně odlišná. V angličtině je relativně běžné, že substantivum popisuje činnost, k jejímuž dějovému vyjádření se užívá sloveso stejné formy (např. *run* vyjadřuje *běh* i *běžet*). U zmíněného českého *stát* sice lze vypořádat poněkud vzdálenou sémantickou příbuznost (pojmenování pro stát jako organizovanou územní a politickou mocenskou jednotku [Oxf03] je zřejmě motivováno jako něco stálého, co dlouho *stojí*), ale není to příliš intuitivní a takové dva výrazy nemohou být zařazeny do stejného konceptu. Slova náležející do odlišných syntaktických kategorií se rovněž syntakticky chovají zcela rozdílně a rozhodně v žádném kontextu nemohou být zaměněna jedno za druhé, což také znemožňuje jejich zařazení do stejného synsetu. [Mil<sup>+</sup>90]

Dalším argumentem pro striktní rozdělení slovní zásoby dle slovních druhů je fakt, že různé slovní druhy mají různou hierarchizaci. Jak bude popsáno v kapitole 1.4 na straně 11, například substantiva jsou hierarchizována podle vztahu hyperonymie a hyponymie, přičemž u nich existují další vztahy jako meronymie, která například u sloves existovat nemůže. Naopak vztah antonymie, který je relativně běžný u adjektiv, se u substantiv téměř nevyskytuje<sup>10</sup>. Verba jsou zase provázána vztahy vyplývání, který u substantiv není příliš evidentní a intuitivní<sup>11</sup>, ale u sloves je vcelku hojný – například z činnosti *zírat* vyplývá i *nadřazená* činnost *hledět*.

Sémantické relace mezi slovy různých kategorií ve WordNetu neexistují, avšak pro tyto případy jsou definovány relace lexikální. Oproti sémantickým relacím, které provazují celé koncepty, jsou lexikální relace definovány na úrovni jednotlivých forem. Dvě stejné formy, například *run*, jedna náležející k substantivům, druhá k verbům, budou propojeny vztahem derivačně příbuzné formy<sup>12</sup>. [Wor]

<sup>10</sup>Lze argumentovat, že např. *život* je antonymem pro *smrt*, faktem ale je, že jde o velmi volnou antonymii – život popisuje stav či průběh doby, kdy je bytost živá, smrt referuje pouze k okamžiku, kdy se z živé bytosti stává mrtvá bytost, tedy rozhodně nejde o přímý protiklad jako například u adjektiv *světlý:tmavý* nebo *špatný:dobry*. Stejně tak např. *Bůh* a *Ďábel* jsou sice proti sobě pokládány bytosti, ale jejich antonymie spočívá spíše ve vlastnostech jim připisovaných, tedy subjektivních, a uživatel jazyka může prohlásit, že obě tyto bytosti jsou špatné, čímž ztratí svou protikladnost.

<sup>11</sup>Asi lze tvrdit, že z *života* vyplývá *smrt*, ale pravděpodobně takto provázaných substantiv nebude mnoho.

<sup>12</sup>derivationally related form

## 1.4 Sémantické vztahy WordNetu

V této kapitole budou podrobněji rozebrány sémantické vztahy konstituující WordNet. Sémantické vztahy jsou, na rozdíl od vztahů lexikálních, které jsou vztahy mezi slovními formami, vztahy mezi koncepty (významy). Rozdíl nejlépe ilustruje protipříklad. Synonymie je typickým vztahem lexikálním; kdyby byla vztahem sémantickým, znamenalo by to, že dva různé významy (koncepty) mají stejný význam, což je nesmysl, jelikož v tom případě to nejsou dva významy, ale jeden.

Struktura těchto vztahů není, jak by se na první pohled mohlo zdát, plochá, ale organizovaná podle syntaktické kategorie významů, jež jsou jimi propojeny. Substantiva mají své vlastní vztahy, stejně tak adjektiva, verba a adverbia. Pojmenování těchto vztahů vychází z lingvistických termínů k nim relevantních (např. hyperonymie) a v některých pojmenování některých se napříč různými syntaktickými kategoriemi překrývá, ačkoliv jde o vztahy různé. Například angl. sloveso *run*<sup>13</sup> má ve WordNetu jako hyperonymum uveden synset s významem *pohybovat se velmi rychle* obsahující slovesa *travel rapidly*, *speed*, *hurry*, *zip*<sup>14</sup>. Je evidentní, že tento vztah hyperonymie není identický se vztahem hyperonymie u substantiv, kde *house*<sup>15</sup> má jako přímé hyperonymum uveden synset *building*, *edifice*<sup>16</sup>. Z činnosti *běžet* vyplývá činnost *rychle se pohybovat*, ale *budova* je pro *dům* nadřazenou třídou. Jde tedy o vztah nikoliv nepodobný, ale ne identický. [Pri]

Vzhledem k vlastnostem sémantických vztahů, jimiž jsou synsety WordNetu provázány, tvoří tyto orientovaný graf (což je v rozporu s obecně značně rozšířenou vizualizací WordNetu jako stromové struktury). Pokud se v tomto grafu vyskytnou anomálie (chyby), může se stát i cyklickým grafem (pokud by například synset měl za hyperonymum sám sebe). To je však zřejmě ojedinělý jev. [Ric08] Zdánlivé cykly ve vizualizaci však nastat mohou, jelikož jeden koncept může mít více hyperonym (více v kapitole 1.4.1 na straně 11), která v určitém bodě budou mít opět společné hyperonymum, jelikož má WordNetu jeden kořen.

### 1.4.1 Hyperonymie a hyponymie

Vztah nadřazenosti a podřazenosti strukturuje především slovní zásobu substantiv. Hyperonymie je vztahem třídy k podtřídě, hyponymie vztahem podtřídy k třídě. Jde o vztah transitivity a asymetrický. [Mil<sup>+</sup>90] Díky této hierarchizaci se lze například vyhnout redundanci ukládání informací v paměti, jelikož příznaky třídy není nutné ukládat u každé podtřídy. Podtřída dědí všechny příznaky své mateřské třídy a přidává minimálně jeden další. Například *tramvaj* je *pouličním kolovým přepravníkem*, který *jezdí po kolejích* a je *pořádán elektrinou*<sup>17</sup>. Pokud některý ze zděděných příznaků pro podtřidu neplatí, je tento fakt u ní explicitně uložen (podrobněji v kapitole 1.2 na straně 8). System, v němž jsou

<sup>13</sup>čes. *běžet*

<sup>14</sup>čes. *cestovat rychle*, *uhánět*, ...

<sup>15</sup>čes. *dům*

<sup>16</sup>čes. *stavba*

<sup>17</sup>a wheeled vehicle that runs on rails and is propelled by electricity

atributy takto děděny se nazývá dědičný systém<sup>18</sup> [Tou86].

Substantiva jsou ve Wordnetu organizována tak, že každý význam má svůj mateřský význam (hyperonymum), kromě jednoho jediného, a tím je *entity*, tedy uměle vytvořený pojem sloužící jako kořen celé sítě. Jeden koncept může mít hyperonymních významů více, například *house* má jako svá hyperonyma uvedeny synsety (n) *dwelling*, *home*, *domicile*, *abode*, *habitation*, *dwelling house* a (n) *building*, *edifice*.

### 1.4.2 Meronymie a holonymie

Meronymie (a k ní komplementární vztah holonymie) jsou, navzdory nepříliš rozšířenému názvosloví, dalším vztahem, jenž je pro uživatele jazyka intuitivní a známý. Jde o vztah *být částí*, potažmo *mít část*. Meronymie je definována tak, že A je meronymem B, pokud A je částí B. Meronymie je vztahem stejně jako hyperonymie transitivním a asymetrickým. [Cru86] Tento vztah také hierarchizuje lexikum do určitých úrovní, ale na rozdíl od vztahu nadřazenosti, v němž obvykle jeden význam mívá jeden až dva nadřazené významy, u vztahu části a celku by byla situace složitější. Je totiž na snadě, že jeden význam může být meronymem mnoha holonymům – kupříkladu *dveře* jsou meronymem u *dům*, *auto*, *šatník*, občas *počítačová skříň*, etc.

Vztah části a celku je vlastní výhradně substantivům.

## 1.5 Lexikální vztahy ve Wordnetu

### 1.5.1 Synonymie

Synonymie je základním definičním vztahem pro synsety ve WordNetu. Na praktických aplikacích je tento jev nejlépe pozorovatelný, jelikož při vyhledání konkrétní formy je uživateli obvykle nabídnut výběr z jednotlivých významů dané formy. Aby byly od sebe významy oné formy odlišitelné, nabídka běžně se obvykle sestává ze seznamu skupin slovních forem náležejících do nalezených synsetů<sup>19</sup> Kupříkladu při vyhledání slova *kolo* v českém wordnetu tak je uživatel konfrontován s několika skupinami, které obsahují zhruba následující:

- *kolo* (1),
- *jízdní kolo* (1), *bicykl* (1), *kolo* (2),
- *kružnice* (1), *cívka* (1), *kolo* (3),

přičemž čísla (zde) v závorce značí index významu dané formy v daném synsetu. Reprezentace v různých aplikacích a různých wordnetech se liší (standardem bývá číslo významu psát za dvojtečku), koncept však zůstává neměnný.

Navzdory zdánlivé jednoduchosti uvedeného konceptu je všeobecnou otázkou, jak synonymii pojímat. Striktní teorie (obvykle připisovaná Leibnizovi) praví, že dvě slova jsou

<sup>18</sup>inheritance system

<sup>19</sup><https://www.englishforums.com/English/AdjectiveSatellite/nwzhv/post.htm#1126701>

synonymní, pokud se jejich záměnou nikdy nezmění pravdivostní hodnota výroku. Lingvistickou interpretací tohoto poněkud matematicko-logického výroku může pak být, že synonymní dvě slova jsou v případě, že se jejich záměnou nikdy neporuší význam (zhruba ona pravdivostní hodnota) a gramatičnost výroku. Je nasnadě, že takto striktně synonymní slova budou pospolu v jazyce těžko přežívat, jelikož je dokázáno, že jazyk tíhne k ekonomičnosti, která by takovým soužitím dvou slov byla hrubě porušena [Lot03]. Pravděpodobně jedinými obecně uznávanými synonymy jsou obvykle dvojice cizího slova a domácího slova, například *internacionální* a *mezinárodní*. Jejich záměnou se velice pravděpodobně nikdy pravdivostní hodnota výroku nezmění, stejně tak jako jeho gramatičnost. Stále však zůstává ve hře stylistika, která může být podobnou náhradou narušena (např. z důvodu cílové skupiny čtenářů či stylistické příznakovosti jednoho ze slov (cf. *zajímavý* a *interesantní*)). Co se tendence k ekonomičnosti jazyka týče, lze předpokládat, že v těchto případech převládá potřeba synonym k eliminaci opakování určitých slov v textu a tím zajištění jeho stylistické uhlazenosti.

Volnější interpretace synonymie počítá ještě s kontextem. Dvě slova jsou synonymní, jsou-li bez způsobení škod nahraditelná alespoň ve stejném kontextu. Jako příklad mohou posloužit formy *board* a *plank*. V kontextu dřevařství mohou tyto dvě formy pravděpodobně bez problému být nahrazeny jedna za druhou, ovšem v případě, že je forma *board* použita ve významu *committee*, těžko ji lze nahradit formou *plank*, neboť by se věta obsahující takové nahrazení stala zcela nesmyslnou.

najít české příklady

Bylo by nanejvýš logické považovat synonymii za vztah diskrétní, tedy že dvě formy buďto synonymní jsou, či nejsou. Z logického hlediska to nepochybně z již uvedeného vyplývá, ovšem lingvisticko-filosofický náhled vycházející z poznatků reálného jazyka na tuto problematiku nahlíží poněkud odlišně. Synonymie v striktním slova smyslu je velice vzácná. Její volnější interpretace je značně častější, ale také výrazně vágnější – kontext, v němž dvě formy synonymní jsou, může být velmi široký, či naopak velice úzký. Záměna některých dvojic (či spíše obecně *n-tic*, volné synonymní řady mohou být vcelku dlouhé – *textil:1, látka:1, textilie:2, plena:1, tkanina:1*) může měnit stylistiku a význam výpovědi více či méně, přičemž ony dvě formy stále dle daných kritérií lze považovat za synonymní. Nelze tedy než vyvodit, že synonymie, minimálně z pohledu přirozeného jazyka, je jevem graduálním, a některé formy jsou tak *synonymnější* než jiné. [Mil<sup>+</sup>90]

cit. český WN

Zaměnitelnost forem podporuje ještě jeden koncept, na němž je WordNet postaven, a to fakt, že jednotlivé významy jsou seskupovány podle slovních druhů. Tento systém vede k jisté redundantnosti, jelikož zvláště v syntetických jazycích, jako je kupříkladu angličtina, lze nalézt mnoho případů, kdy identická slovní forma zastupuje více slovních druhů. Významy, které taková slovní forma zastupuje (napříč slovními druhy), mohou být velice blízké, nikdy však nebudou stejné (nelze říci, že význam slovesa *run*<sup>20</sup> a substantiva *run*<sup>21</sup> je identický). Jejich záměnou by se sice nestalo vůbec nic, jelikož čtenář či posluchač textu, v němž taková záměna nastala, by automaticky formu interpretoval ve prospěch správného slovního druhu, avšak pokud by slovní druh byl nějakým způsobem „vynucen“ (nechtě nyní čtenář pomine úvahy, jakým způsobem lze *vynutit* slovní druh formy), stala

manko, nekecam?

<sup>20</sup>běžet

<sup>21</sup>běh

by se výpověď zcela negramatickou a nesmyslnou.

Jakkoliv to není přímo svázané se synonymií, je na místě poznámka o výskytu stejné formy v různých synstetech. Slovo je kombinací slovní formy a významu, nebo slovního významu. Slovní forma je projevem „fyzickým“, tedy je to vyřčená či napsaná instance významu. Jak je zjevné z přirozeného jazyka, nelze počítat s tím, že by zobrazení významu na formu bylo bijektivní, tedy každý význam byl namapován jedna ku jedné na slovní formu. V přirozeném jazyce může jedna forma zastupovat více významů a jeden význam může být vyjádřen více formami. Příkladem budiž slovní forma *koruna*, která může zastupovat význam měny, vrcholku stromu, vladařského odznaku, etc. Toto zobrazení jedné formy na více významů se nazývá polysémií nebo homonymií<sup>22</sup>. S polysémií souvisí ještě homonymie, což ve své podstatě dosti podobný vztah, ale totožnost formy je zcela nahodilá. Kupříkladu formu *kolej* lze interpretovat jako referenci k stopě po voze, případně dvojici kolejnic jako vodící dráze pro dopravní prostředky a zároveň jako zařízení vysoké školy pro ubytování studentů. U významů formy *koruna* lze vypořádat nějaký společný základ (koruna stromu je nahoře, panovníckou korunu má panovník na hlavě, tedy nahoře, koruna jako mince zase pravděpodobně získala své pojmenování díky faktu, že na mincích bývá vyobrazen panovník). Naproti obě formy *kolej* pochází z odlišného základu – *kolej* jako ubytovací zařízení pochází z latinského *collegium*, kdežto výraz pro dráhu je odvozeno od českého *kolo*.

ne, není, ale nech-telo se mi mazat 2k napsaných znaku xD

cit. SSJC

cit SSJC

Seskupování významů podle slovních druhů a seskupování forem dle vztahu synonymie se tedy zdá v případě lexikální databáze určené pro strojové zpracování jako vhodným konceptem. Oproti tradičním slovníkům se totiž počítačově zpracovávaná lexikální databáze nemusí potýkat s problémem lidského faktoru – jednotlivé synonymické řady je stroj schopen prohledávat, na rozdíl od člověka, velice účinně, a nahradí tak v případě, že WordNet používá člověk, neúčinné lidské procházení restříkovaného obsahu.

cit: etymo-log, slov-ník, ale jeho online verze to neuvadí

psano v chvatu, mohlo by se to mozna trochu uhladit...

### 1.5.2 Antonymie

Antonymie, neboli protiklad, je navzdory zdánlivé triviálnosti koncept překvapivě těžce definovatelný. Všeobecně se antonymií rozumí významová opozice, faktem však je, že použití tohoto termínu je velmi široké a druhů antonymie je několik. Nejjednodušším druhem je například antonymie mezi adjektivy *živý* a *mrtvý*. Negace prvního automaticky značí druhé a naopak (je-li řeč o živých bytostech), jelikož v reálném světě neexistuje žádný další třetí stav. Tento jednoduchý vztah však nefunguje vždy – například s adjektivy *bohatý* a *chudý* je to jiné. Mnoho lidí se nepovažuje ani za chudé, ani za bohaté, a tudíž z toho, že někdo není bohatý, automaticky neplyne to, že by byl chudý. Miller et al. [Mil<sup>+</sup>90] Zajímavé je, že tento vztah není reflexivní. Pokud někdo není bohatý, tak to nemusí znamenat, že je chudý, ale pokud je o někom tvrzeno, že *je* bohatý, tak to nutně znamená, že *není* chudý. Paradis; Willners [PW06]

Rozdíl mezi výše uvedenými dvojicemi, tedy *mrtvý:živý* a *chudý:bohatý* spočívá ve stupňovatelnosti daných adjektiv. Pro ilustraci – lze říci, že někdo je *bohatší* než někdo jiný, ale

<sup>22</sup>obojí znamená totožnost formy pro různé významy, u polysémie však ony významy mají společný základ (byt může být velmi vzdálený)

nelze říci, že někdo je *mrtvější* než někdo jiný. Pokud jsou adjektiva stupňovatelná, tedy lze říci, že objekt A je více X než objekt B, neoznačují komplementární stav, ale graduální vlastnost. Označované pak může být zařazeno kamkoliv mezi tyto dva póly, přičemž nachází-li se v pomyslné střední šedé zóně, nelze jej označit výrazy odpovídajícími pólům gradientu. Tvrzení, že někdo *není ani chudý, ani bohatý*, dává smysl, protože tato adjektiva označují extrémní stavy, mezi nimiž je prostor pro normální stav. Paradis; Willners [PW06]

Vztah antonymie ve WordNetu je koncipován tak, aby zřejmě byl co nejpodobnější uvažování široké populace uživatelů jazyka, tedy užívá primitivního konceptu antonymie. Některé studie dokonce za antonymní považují výrazy pouze vágně, intuitivně protikladné, jako například muž:žena či chytrý:hloupý. [LL82]

Ve WordNetu se antonymie vyskytuje u substantiv (*man:woman*), adjektiv (*rich:poor*, a dokonce i *white:black* v rasovém významu<sup>23</sup>), verb (*open:close*) i adverbíí (*well:ill*).

---

<sup>23</sup>cf. také antonymní vztah *Caucasian:black* ve WN



## Kapitola 2

# Další wordnety

Podle vzoru princetonského WordNetu začaly postupně vznikat i další sémantické sítě založené na stejném konceptu. Tyto sémantické sítě se samozřejmě svou strukturou do větší či menší míry liší, hlavním kritériem pro to, aby mohly být považovány za wordnet, je to, aby obsahovaly synsety a hyponyma. [Theb]

nakou  
kurva ci-  
taci

### 2.1 EuroWordNet

EuroWordNet je mezinárodní lexikální databáze pro osm evropských jazyků (angličtina, čeština, dánština, francouzština, italština, němčina, španělština). Jde o soubor jednotlivých národních wordnetů, které jsou propojeny takzvaným mezijazykovým indexem (ILI, *inter-lingual-index*). Obecně jsou wordnety Eurowordnetu založené svou strukturou na princetonském WordNetu (verze 1.5), ale z důvodu různorodosti jazyků se v některých aspektech od něj odlišují.

Základní motivací pro vznik EuroWordNetu byla evropská jazyková různorodost a z ní pramenící problémy ve zpracování dat a napomáhání uživateli v přístupu k neanglickým datům. Vossel 1999 (Vossen-Eurowordnet.pdf, pg XX) argumentuje, že uživatel musí umět anglicky a být obeznámen s tím, jak je zdroj, v němž vyhledává napsán, aby byl schopen v něm účinně hledat. Vytvořením wordnetů pro jiné jazyky si slibuje, že se zlepší možnost přístupu uživatelů k neanglickým datům, možnosti inference znalostí z těchto dat a případně i mezijazykové vyhledávání. Poslední je založeno na faktu, že od počátku byly jednotlivé wordnety EuroWordNetu vytvářeny s tím, že budou propojeny na základě základních konceptů (BCS, *Base Concepts*) a mezijazykového indexu.

Jelikož se jednotlivé jazyky zapojené v projektu EuroWordNetu značně odlišují ve struktuře své slovní zásoby, jsou jednotlivé wordnety nezávislé. To znamená, že se mohou odlišovat například svou hierarchizací. Stejný koncept tak může ve dvou různých wordnetech mít různá hyperonyma, meronyma, etc., protože například anglické označení pro prst je odlišené, pokud jde o prst na noze (toe), či na ruce (finger). Podobně má v jiném příkladu dánština odlišené označení hlavy u zvířat vyjma koní, tedy kof, a hlavy lidské a koňské (hoofd). [Vos97]

rikam to  
dobře? vu-  
bec jim  
nerozu-  
mím

nekde  
jsem to  
cetl, ale  
nemuzu to  
dohledat  
(a slov-  
nik to po-  
pira, tak  
to mozna  
bude jiny  
jazyk...  
dunno, TB  
fixed

Relace	Slovnědruhov $\acute{e}$ kombinace	Př $\acute{e}$ klad
antonymie	A-A, V-V	open:close
hyponymie	N-N, V-V	car:vehicle, walk:move
meronymie	N-N	head:nose
vypl $\acute{y}$ vání <sup>1</sup>	V-V	buy:pay
následek	V-V	kill:die

Tabulka 2.1: Vztahy přejaté z princetonského WN (N: substantivum, A: adjektivum, V: verbum)

Národní wordnety jsou vzájemně propojené přes mezijazykový index s anglickým wordnetem, který je obsahově založený na princetonském WordNetu, ale není identický. Anglický wordnet byl přizpůsoben strukturně tak, aby byl použitelný v EuroWordNetu, tedy byly přidány dodatečné metainformace a druhy vztahů (podrobněji dále). V národních wordnetech existuje několik druhů konceptů, které jsou rozlišeny podle příbuznosti s koncepty v ostatních národních wordnetech. Pokud je koncept přítomen ve všech wordnetech EuroWordNetu, jde o koncept tzv. *Global Base Concept* (GBC). Koncept, jenž jen přítomen v alespoň dvou národních wordnetech je označován jako *Common Base Concept* (CBC) a v poslední řadě koncept, který se vyskytuje pouze v jednom národním wordnetu nese označení *Local Base Concept* (LBC). [Thea] Propojení konceptů společných pro více jazyků je zajištěno pomocí jednotných identifikátorů a mezijazykového indexu, který je nadmnožinou všech konceptů v EuroWordNetu. ILI je hierarchicky plochá struktura (proto *index*, nejde o další „všejazykový“ wordnet). [Vos97]

Jelikož v době, kdy EuroWordNetu vznikal, byl princetonský WordNet poněkud omezený mimo jiné co se vztahů mezi slovními druhy týče, vznikly pro EuroWordNet speciální vztahy umožňující úplnější práci s významy. Základní vztahy přejaté z princetonského WordNetu 1.5 jsou uvedeny v tabulce 2.1 na straně 17.

Navíc k těmto vztahům byly přidány štítky (*labels*), jež relaci konkretizují. Byly použity následující štítky:

- conjunction/disjunction
- non-factive
- reversed
- negation

nikdy jsem to nevidel, pls je to nekde v nasich WN na debdictu?

Použití konjunktivního a disjunktivního štítku spočívá v myšlence, že například u meronymie by bylo vhodné rozlišovat, zda jde o části, které dohromady tvoří celek, nebo jde o podčásti částí (např. nůž má meronyma čepel, rukojeť, ostří, ale ostří je ve skutečnosti meronymem až rukejeti, nikoliv přímo samotného nože).

Štítek *non-factive* je používán u kauzální relace, která nemusí být nutně naplněna:

Podobně lze upřesnit pomocí štítků další relace tak, že jsou ve výsledku jednoznačnější a wordnet, v němž jsou takto označené vztahy obsaženy, může poskytovat více informací.

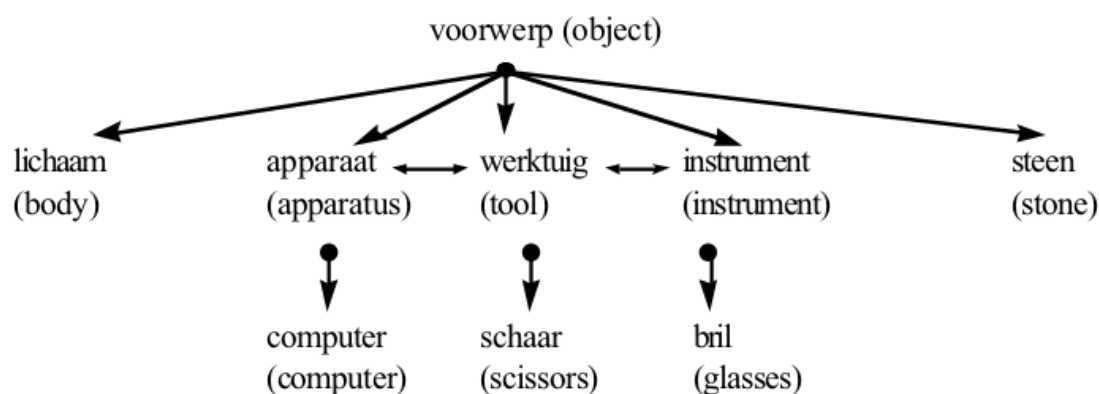
vubec netusim, jestli to chapu spravne, spis mi prijde, ze ne..

jak to prelozit? nezda se mi, ze by to melo s timhle cokoliv spolecneho:  
<https://goo.gl/7Z>

příčina	vztah	následek	non-factive?	nutně vyplývá?
zabít	<i>vyúští v</i>	zemřít	–	ano
hledat	<i>vyúští v</i>	najít	non-factive	ne

Jako další vylepšení oproti tehdejší verzi princetonského WordNetu přinesl EuroWordNet také relace mezi slovními druhy a vztah blízkého synonyma. Argument pro zavedení mezislovnědruhových relací je relativně přímočarý, a to, že umožňují „sblížit“ koncepty, které jsou si příbuzné, jen náleží k jinému slovnímu druhu. Nutno podotknout, že v době vzniku této práce je princetonský WordNet ve verzi 3.1 a obsahuje už relaci *derivationally related form*, která zajišťuje přesně toto propojení (více o synsetech v princetonském WordNetu v kapitole 1.3.1 na straně 9). Co se vztahu blízkého synonyma (*near synonym*) týče, důvodem pro jeho zavedení byl údajně zájem mít možnost přiblížit koncepty, které jsou si významově podobné, ale pouze na své úrovni. U takových konceptů platí, že byť jejich význam je podobný, jejich hyponyma nelze zařadit pod jeden koncept, jelikož se rozdíl mezi oněmi koncepty svázanými vztahem blízkého synonyma prohlubuje. Příkladem budiž trojice nizozemských slov *aparaat*, *werktuig* a *instrument*, jež jsou si významově nepříliš vzdálená:

hmm, a co near antonym? to be investigated



Obrázek 2.1: Blízká synonyma (k překreslení)

Jak je z obrázku 2.1 na straně 18 zřejmé, všechna hyponyma slova *voorwerp* (objekt) jsou si rovna, avšak některá jsou si rovnější. Tři výše zmíněná slova jsou si navzájem významově výrazně bližší, než jsou si blízká s ostatními hyponymy na jejich úrovni. Právě aby bylo možno tento vztah reflektovat a tím docílit možnosti například nahrazovat za sebe slova, která sice nemohou být ve stejném synsetu, ale jsou si podobná, byl zaveden vztah blízkého synonyma. Lze totiž předpokládat, že uživatel jazyka podobná slova také může zaměnit. [Vos97]

smím v diplomce delat reference na kvalitní literaturu? xD

cela ta kapitola je v podstate z toho vos-sena, tak nevím, jak to citovat :/

## poznámky

Jak moc mam rozebírat další wordnety (resp. site WN, jako je Eurowordnet, balkanet...)?

Jak dál: Dal bych chtěl rozebrat nějak obecně vizualizace WN (ze ne všechno lze nacpat do jedny), jaky se obecně volí přístupy (fuck everything, dělame jen hyponymii, většinou), a pak vybrat pár nejakejch dobře přístupnejch a/nebo originalnich, který rozebrat, proč jsou špatny...

### co nechapu:

- adjektiva (jakýsi model s kolem (střed kola nějaké core), sprinčikama k obvodu (vztahy k "satellite adjectives"), osa k dalšímu "středu kola"... )
- nevím, kde najít rozdíly mezi Princeton WN verzema (1.5 vs 2.1 vs. 3.0)

## Část II

# Přehled a porovnání existujících vizualizací sémantických sítí

Tato část textu bude zaměřena na zmapování existujících dostupných rozhraní a jejich zhodnocení. Výčet jednotlivých rozhraní rozhodně není vyčerpávající, jelikož některé vědecké instituce mohou vyvíjet své nástroje pro práci se sémantickými sítěmi neveřejně, některé nástroje už nejsou dostupné, etc. Nástroje pro vizualizaci<sup>2</sup> dat wordnetů byly vybírány pro přehled v této práci podle několika kritérií relevantních především pro koncového uživatele, avšak i pro případné vývojáře dalších wordnetů (tedy zda dané rozhraní mohou použít pro svá data).

---

<sup>2</sup>Terminologická poznámka: v této práci je vizualizací dat wordnetů míněna vizualizace jak textová reprezentace, tak grafická.

## Kapitola 3

# Metodologie porovnání

### 3.1 Výběr rozhraní

Hlavním kritériem pro zařazení do rozhraní do výběru byla jeho dohledatelnost podle vyhledávacího dotazu na indexovací a vyhledávací webové stránce <https://www.google.com>. Dotazy byly voleny tak, aby bylo dosaženo co nejvyšší relevance vyhledaných výsledků:

- wordnet visualization
- wordnet visualisation
- wordnet graph

Z přehledu byly samozřejmě vyřazeny implementace, které k době hledání<sup>1</sup> už nebyly dostupné. Také nebyla zahrnuta rozhraní, která jsou funkčně podobná jiným. Ačkoliv většina existujících rozhraní zřejmě pracuje buďto výhradně s princetonským WordNetem, či jej jako zdroj dat nabízí jako jednu z možností, nebylo na toto bráno ohled. Do přehledu byla zahrnována především rozhraní, která jsou dostupná z webového prohlížeče, jelikož je to pro koncového uživatele nejpohodlnější způsob přístupu k aplikaci (není nucen instalovat žádný přídatný software na svůj počítač), ovšem vzhledem k rozšířenosti rozhraní určených pro aplikační prostředí Java byla do přehledu zahrnuta i některá rozhraní právě tohoto typu. Jsou však popisována pouze povrchněji a měla by při interpretaci hodnocení být automaticky značně penalizována, jelikož je uživatel mající zájem takové rozhraní použít nucen instalovat aplikační rozhraní Java, pokud jej nemá. Dalším důvodem k penalizaci je také fakt, tyto aplikace nejsou přímo spustitelné na mobilních zařízeních<sup>2</sup> [Gro<sup>+</sup>14] a jejich portabilita do formy nativních aplikací může omezená a obtížná.

Podstatná z hlediska hodnocení je také univerzalita, tedy zda je zdrojový kód rozhraní otevřený a je možné jej použít i pro vizualizaci jiné sémantické sítě, než pro kterou bylo

---

<sup>1</sup>20. dubna 2017

<sup>2</sup>Pro Android existuje emulační rozhraní XY link, lze však předpokládat, že použitelnost vizualizací wordnetu bude na zařízení s malou obrazovkou poněkud omezená.

rozhraní vyvinuto. Je ovšem dlužno podotknout, že tato informace bývá často nedostupná; potom se v rámci této práce předpokládá, že kód otevřený není.

Do přehledu byla tedy zahrnuta následující rozhraní:

- An interactive visualization of the Princeton WordNet database (<http://mateogianolio.com/wordnet-visualization/>)
- WordNET Editor (<http://wordventure.eti.pg.gda.pl/wne/wne.html>)
- Cornetto Demo ([http://cornetto.clarin.inl.nl/wordnet.xql?ssID=&word\\_form=&pos=&sense\\_pos=1](http://cornetto.clarin.inl.nl/wordnet.xql?ssID=&word_form=&pos=&sense_pos=1))
- WordVis (<http://wordvis.com/>)
- sloWTool (<http://nl.ijs.si/slowtool/>)
- BabelNet (<http://babelnet.org>)
- wnbrowser<sup>3</sup> (<http://homepages.inf.ed.ac.uk/adubey/software/wnbrowser/index.html>)
- Visual Browser (<https://nlp.fi.muni.cz/projekty/visualbrowser/>)
- Treebolic ()
- Artha (<http://artha.sourceforge.net/wiki/index.php/Home>)
- GoldenDict (<http://goldendict.org/>)

Pro účely porovnání (určení východiska) bude do popisu zahrnuto ještě jedno rozhraní, a to oficiální vyhledávací rozhraní princetonského WordNetu (<http://wordnetweb.princeton.edu/perl/webwn>).

well, baseline

## 3.2 Strukturalizace přehledu a kritéria hodnocení

Výše vypsaná rozhraní budou v dalších kapitolách rozdělena podle toho, zda umožňují přístup z webového prohlížeče (nativně, bez nutnosti mít nainstalované prostředí Java), budou zhodnoceny jejich positiva a negativa z hlediska použitelnosti pro získání informací o hledaném výrazu a v neposlední řadě také podle toho, jak kvalitní jejich uživatelské rozhraní je.

neja-  
kej link,  
možná vy-  
svetlení?

K rozdělení podle dostupnosti bylo přistoupeno jednak proto, že v době vzniku této práce je pokročilost webových technologií dostatečná k tomu, aby podobné vizualizace byly tvořeny jako webové stránky, a jednak proto, že cílem této práce je vytvořit všeobecně dostupné a použitelné rozhraní k wordnetům. Všeobecně použitelným je míněna použitelnost nejen na osobních počítačích, ale také na mobilních zařízeních, což v podstatě

---

<sup>3</sup>sic erat scriptum



vyřazuje použití technologií jako jsou zásuvné moduly Java používané k realizaci různých existujících rozhraním (příkladem budiž Visual Editor).

Rozhraní jsou hodnocena na základě několika kritérií. Cílem je porovnat jejich přínos v kontextu ostatních existujících rozhraní a v kontextu současných trendů webových aplikací a ilustrovat, s jakými problémy se všeobecně rozhraní potýkají. Z tohoto důvodu právě nebyla do přehledu zařazována rozhraní, která se podobají svou funkcionalitou a ovládáním rozhraním již zařazeným. Kritéria hodnocení v této práci jsou následující:

- přínos oproti základnímu oficiálnímu rozhraní princetonského WordNetu
  - originální vizualizace dat vedoucí k možnosti identifikovat trendy v datech, které zůstávají uživateli skryty případně základní textové reprezentace dat
  - reprezentace dat vhodnější z hlediska zásad přístupnosti webu<sup>4</sup>
- responsivita rozhraní – kvalitní použitelnost rozhraní i na zařízeních s menší obrazovkou, jako jsou mobilní zařízení typu chytrý telefon či tablet
- v případě webových aplikací ukládání stavu aplikace v adresním řádku prohlížeče (umožňuje sdílení nebo založení odkazu ke konkrétnímu hledání a zachování nastavení aplikace)

### 3.3 Podmínky testování

Pro testování rozhraní, které bylo pro účely této práce provedeno, byl použit operační systém Ubuntu 16.04 LTS v 64bitové verzi, webový prohlížeč Pale Moon ve verzi 27.1.1 (rovněž 64bitový) s nastaveným uživatelským agentem na Firefox (z důvodů kompatibility). Ačkoliv se počítalo, vzhledem k nepříliš rozšířenému vykresovacímu jádru toho prohlížeče, s možnými problémy v zobrazení některých rozhraní, nebyly tyto zjištěny, a tak nebylo nutné provádět testování rozhraní ještě v dalších prohlížečích. Lze předpokládat, že v rozšířených prohlížečích, jako jsou Firefox či Chrome, budou jednotlivá rozhraní fungovat a vypadá podobně, jako v prohlížeči Pale Moon.

Testování na mobilním chytrém telefonu bylo prováděno na zařízení Nexus 5 (displej s úhlopříčkou 5" a rozlišením 1080 × 1920 px) s operačním systémem Android 6 v prohlížeči Chrome (sestavení 57.0). Možnost *request desktop site* byla nastavena na *vypnuto*.

### 3.4 WordNet Search jako základ porovnání

Oficiální rozhraní k princetonskému WordNetu je koncipováno jako textová reprezentace dat, přičemž, byť volitelně, umožňuje zobrazovat veškeré k hledanému výrazu relevantní informace, jež WordNet obsahuje. Data jsou vizualizována jako soubor seznamů.

Po vyhledání zadaného výrazu jsou uživateli prezentovány v bodech jednotlivé synsety obsahující hledanou slovní formu rozdělené podle slovních druhů, k nimž přináležejí.

---

<sup>4</sup>web accessibility

V základním nastavení každý bod sestává ze slovních forem tvořících daný synset, jeho definici, případný příklad užití a odkaz na details synsetu. Kliknutím na tento odkaz se zobrazí v podseznamu sémantické a lexikální relace, v nichž je daný synset přítomen. Samotné relace jsou opět odkazy, jejichž otevřením je uživateli prezentován seznam synsetů, které jsou spolu s daným synsetem v dané relaci přítomny. Postupným otevíráním detailů synsetů v podseznamech se lze zanořovat hlouběji a hlouběji do struktury, resp. se ve struktuře vzdalovat původnímu synsetu po hranách relací.

Uživatel má možnosti si zvolit množství informací, jež jsou mu prezentovány, a to od úplného minima (pouze slovní formy nalezených synsetů a jejich syntaktické kategorie) až po vše, co se ve WordNetu vyskytuje, včetně identifikátorů a dalších technických detailů. Rozhraní svůj stav ukládá jako parametry URL<sup>5</sup>, takže je možné jej později obnovit z adresy.

Rozhraní není responsivní, ale vzhledem k tomu, že je v základu relativně úzké (pod 700 px), je na chytrém telefonu použitelné.

Podobnou jako WordNet Search splňují i některá další rozhraní. Za zmínku stojí například WNSearch<sup>6</sup>, což je minimalistické čistě textové rozhraní, které díky absenci jakýchkoliv stylů je responsivní a dobře použitelné na mobilních zařízeních s libovolně velkým displejem. Mezi další rozhraní s podobnou funkcionalitou patří URCS Wordnet Browser (pro Javu)<sup>7</sup> či GoldenDict (rozhraní pro stolní počítače<sup>8</sup>)<sup>9</sup>.

---

<sup>5</sup>Uniform Resource Locator

<sup>6</sup><http://www.golovchenko.org/cgi-bin/wnsearch>

<sup>7</sup><http://www.cs.rochester.edu/research/cisd/wordnet/>

<sup>8</sup>myšleno všeobecně pro zařízení typu stolních počítačů, laptopů, případně tabletů etc., na nichž je provozován operační systém nikoliv určený pro mobilní zařízení

<sup>9</sup><http://goldendict.org/>

Word to search for:

Display Options:

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations

Display options for sense: (gloss) "an example sentence"

### Noun

- **S: (n) wheel** (a simple machine consisting of a circular frame with spokes (or a solid disc) that can rotate on a shaft or axle (as in vehicles or other machines))
  - [direct hyponym](#) / [full hyponym](#)
  - [part meronym](#)
  - [direct hypernym](#) / [inherited hypernym](#) / [sister term](#)
    - **S: (n) machine, simple machine** (a device for overcoming resistance at one point by applying force at some other point)
      - [direct hyponym](#) / [full hyponym](#)
      - [direct hypernym](#) / [inherited hypernym](#) / [sister term](#)
        - **S: (n) mechanical device** (mechanism consisting of a device that works on mechanical principles)
  - [part holonym](#)
  - [derivationally related form](#)
- **S: (n) steering wheel, wheel** (a handwheel that is used for steering)
- **S: (n) wheel** (forces that provide energy and direction) "*the wheels of government began to turn*"
- **S: (n) wheel** (a circular helm to control the rudder of a vessel)
- **S: (n) roulette wheel, wheel** (game equipment consisting of a wheel with slots that is used for gambling; the wheel rotates horizontally and players bet on which slot the

Obrázek 3.1: Ukázka rozhraní: WordNet Search 3.1 v základním nastavení a s otevřenými detaily synsetů

## Kapitola 4

# Vizualizace s webovým rozhraním

Jako bylo naznačeno v úvodu této části, vizualizací s webovým rozhraním se v této práci míní taková implementace, která ze strany uživatele nevyžaduje instalaci žádných doplňujících aplikací či aplikačních prostředí kromě samotného webového prohlížeče.

lze takhle nazvat Javu?

### 4.1 An interactive visualization of the Princeton WordNet database

Jeden z projektů programátora jménem Mateo Gianolio z Lundské univerzity (Švédsko). Jde o jednoduché rozhraní napojené na princetonský WordNet, které po zadání hledaného výrazu zobrazí synsety obsahující daný výraz. Jednotlivé synsety jsou barevně odlišeny podle syntaktických kategorií (slovních druhů), k nimž náležejí, a uspořádány kruhově kolem hledaného výrazu. Z každého synsetu je vždy zobrazena jen první slovní forma. Pokud uživatel najede kurzorem myši na některý ze synsetů, zobrazí se další případné slovní formy náležející do daného synsetu a jeho glosa (definice), je-li dostupná.

src:  
<https://www.linkedin.com/in/mateo-gianolio-a89558b6/?trk=pr-badge-name>

Další slovní formy v nalezených synsetech jsou klikatelné, což umožňuje dostat se přesně na synsety obsahující onu slovní formu, na níž bylo uživatelem kliknuto (s identickým výsledkem, jako kdyby dané slovo uživatel zadal do vyhledávacího pole).

Ačkoliv úvodní odstavec na stránce s rozhraním vybízí uživatele k „prozkoumání de-sambiguace slov“, zobrazují výsledky hledání pouze synsety a slovní formy do nich náležející, přičemž synsety připojené sémantickými vztahy hyponymie, meronymie etc. nejsou zobrazitelné (jinak než případným náhodným výskytem jedné slovní formy ve více synsetech). To použití WordNetu omezuje na obyčejný thesaurus.

cit web

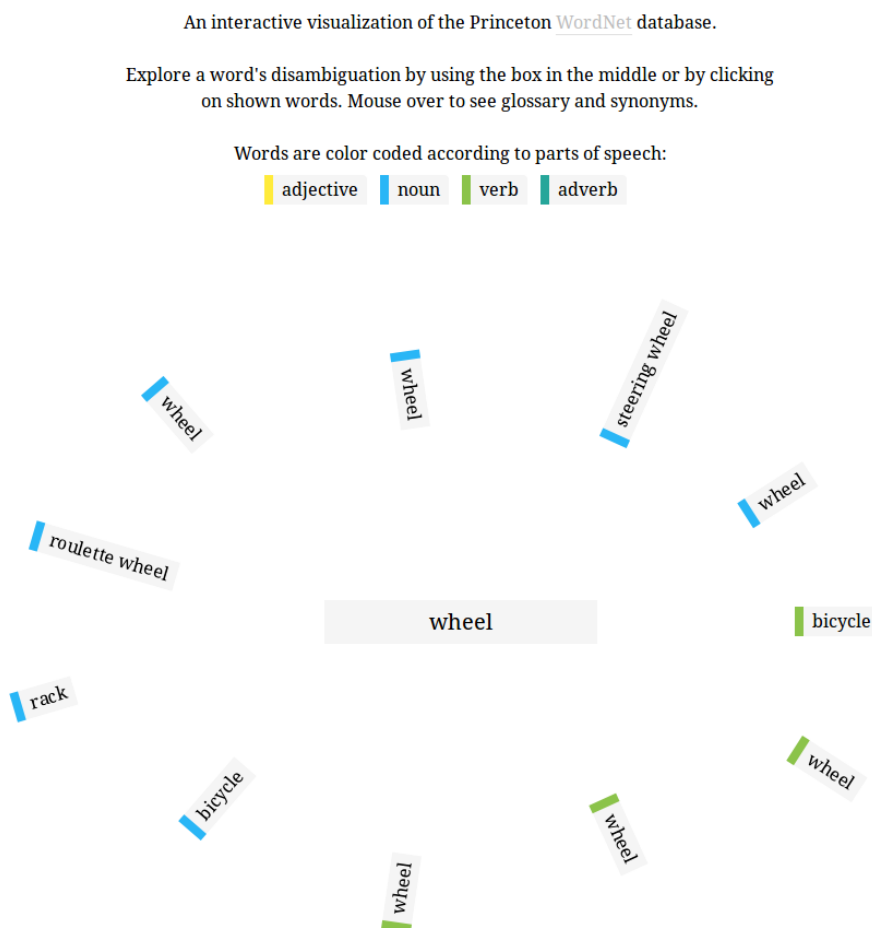
Samotný design grafického rozhraní je řešen poněkud nešťastně a působí dojmem, že cílem autora bylo prokázat své schopnosti používat různé standardní transformační funkce CSS. Pro indikaci běžícího procesu vyhledávání byl použit efekt rotační animace pro vyhledávací pole a po dokončení vyhledávání jsou výsledky zobrazeny paprskovitě okolo vyhledávacího pole. To způsobuje, že některé texty jsou zobrazeny pod úhlem až 90 stupňů, což může pro některé uživatele činit jejich přečtení obtížnějším.

odkazat na kapitulu o CSS nekde dal a možná to, že to je fakt v CSS...

Rozhraní není tzv. responsivní, tedy nepřizpůsobuje se velikosti obrazovky, na níž je

zobrazeno.

Toto rozhraní tedy poskytuje velice omezený přístup k datům WordNetu a neposkytuje žádné výhody oproti základnímu oficiálnímu rozhraní k princetonskému WordNetu. Jeho grafické pojetí je čistě arbitrární, neslouží žádnému účelu a naopak zhoršuje jeho použitelnost.



Obrázek 4.1: Ukázka rozhraní An interactive visualization of the Princeton WordNet database

## 4.2 WordNET Editor

Webová aplikace WordNET Editor byla vytvořena s cílem poskytnout internetové komunitě praktický a účinný nástroj pro rozvoj WordNetu. Její autoři argumentují, že jelikož vývoj WordNetu vyžaduje velké množství lidské práce, a je proto důležité jej tvořit tak, jako je tvořena internetová encyklopedie Wikipedie, tedy kolaborací nezávislých uživatelů.

[SDB07] K tomu je však potřeba nástroj, který takovou spolupráci umožní, což podle nich oficiální nástroje princetonského WordNetu nejsou (mimo jiné pravděpodobně proto, že WordNet byl vyvíjen uzavřenou skupinou lidí [Fel05]). Vedle editoru vztahů a synsetů však obsahuje WordNET Editor i prohlížeč wordnetu, pro který bylo rozhraní do tohoto přehledu zařazeno. Data, jež aplikace používá, jsou verzí princetonského WordNetu odvětvenou v jeho verzi 2.1. [SDB07]

Rozhraní je rozděleno do levého sloupce a pravého (většího) „plátna“, jež slouží pro grafické vyobrazení vztahů. Po vyhledání zadaného výrazu nabídne aplikace uživateli seznam synsetů, v nichž se výraz nachází. Nabídka synsetů je klikatelná a po uživateli je po zvolení synsetu kliknutím prezentováno grafické vyobrazení daného synsetu se všemi jeho vztahy. V levém sloupci si pak uživatel může vybírat, další synsety, které chce do pravé sekce přidat, může také otevírat dvojklikem již zobrazené synsety a lze i v nastavení filtrovat, které vztahy a slovní druhy se mají zobrazovat. Aplikace však zřejmě neobsahuje intuitivní způsob jak zobrazené synsety z plátna vpravo odebírat zobrazené synsetu a při otevírání dalších plátno nepřepisuje, ale synsety přidává k existujícím (neprovázaně). To může vést ke značné nepřehlednosti reprezentace, avšak aplikace umožňuje přibližování a oddalování plátna a vizuální přesouvání zobrazení po plátně, což s jistým úsilím uživatele nepřehlednost může eliminovat. Také nutno vytknout absenci textového pojmenování vztahů mezi synsety. Barevné rozlišení je v tomto případě nevhodně zvolené, jelikož vztahů je v rozhraní hodně a některé barvy jsou obtížně odlišitelné.

Grafické zobrazení vztahů mezi koncepty je řešeno hvězdčovitě, přičemž ve středu je zvolený synset, jenž byl výsledkem hledání, a od něj jsou vedeny hrany představující vztahy k příbuzným synsetům. Zajímavý je originální koncept zobrazení synsetů příbuzných k hledanému (otevřenému) synsetu. Ten je v grafu reprezentován svými členskými slovními formami, ale příbuzné koncepty jsou reprezentovány svými definicemi. Trochu na závadu však je, že se zřejmě nedá (minimálně v prohlížečím režimu) zobrazit detail příbuzného synsetu a uživatel se dozví pouze jeho definici, nikoliv slovní formy do něj náležející. Jediný detail, který je uživateli dostupný, je u některých synsetů obrázek (o jeho zdroji se však v rozhraní nepíše).

Test chování tohoto rozhraní na mobilním zařízení nebyl proveden, jelikož je zjevné, že je určeno především k editacím a podle toho je také navrženo. Rozhraní poskytuje grafický náhled na strukturu dat, ale pro nevhodné kódování vztahů do barev a nezobrazování dostatečného množství informací je jeho ovládání neintuitivní. Nutno podotknout, že rozhraní tak, jak je vyobrazeno v Szymanski et al. [SDB07], vypadá značně odlišně a například obsahuje pojmenované vztahy.

Podle webové stránky projektu je rozhraní vyvinuto s otevřeným zdrojem, pro jeho obdržení je však nutno kontaktovat vývojáře. Lze ale předpokládat jeho použitelnost i pro ostatní wordnety.

cit  
<http://wordventure.eti.pg.gda.pl/>

### 4.3 Cornetto Demo

Cornetto Demo je prohlížeč pro nizozemský wordnet a jako jedno z mála dostupných webových aplikací kombinuje grafickou a textovou vizualizaci dat. To je dáno zřejmě mimo jiné



Obrázek 4.2: Ukázka rozhraní WordNET Editor: zvolený synset ve středu grafu a zobrazený obrázek k příbuznému synsetu

tím, že Cornetto Demo není pouze rozhraním pro wordnet, ale kombinuje data ze dvou zdrojů. Jednak z Referentie Bestand Nederlands [MM05], a jednak z nizozemského wordnetu. Referentie Bestand Nederlands je slovník obsahující informace podobně strukturované jako FrameNet [FBS04] spolu s rozšířením o kombinatorické chování slov v určitém významu [HVR].

Rozhraní je rozděleno na tři moduly, základní vyhledávání, pokročilé vyhledávání a vizualizace synsetů.

Základní vyhledávání slouží k prostému vyhledávání lexikálních jednotek. Dotaz je možné základním způsobem omezovat či rozšiřovat, a to pomocí zástupných znaků (\*, ?<sup>1</sup>) a volby slovních druhů, v jakých se má vyhledávat. [Cor]

Pokročilé vyhledávání umožňuje v nizozemském wordnetu najít lexikální jednotky, které mají společné specifické parametry. Jako kritéria pro vyhledávání lze zvolit kterékoliv kombinace všech příznaků, jež jsou ve wordnetu u lexikálních jednotek přítomny. Takto je možné například vyhledat všechna slovesa, která jsou řazena do domény tance a jsou označena jako archaická.

Pokud hledaný výraz či zvolená kritéria odpovídají některým lexikálním vyskytujícím se v databázi, je uživateli prezentován seznam nalezených jednotek, přes něž se lze prokliknutím dostat na detail té které jednotky. Detail je textovou reprezentací dostupných

<sup>1</sup>přičemž \* zastupuje posloupnost kterýchkoliv znaků, ? zastupuje jeden kterýkoliv znak

dat, tedy syntaktických a sémantických informací o vyhledaném slově (nutno podotknout, že značná část informací v této části zřejmě pochází spíše Referentie Bestand Nederlands, nikoliv z wordnetu) a hierarchického zařazení konceptu, do něž slovo patří, ve wordnetu. Hierarchické zařazení je vyvedeno ve formě podobné tradičnímu znázornění adresářového stromu a obsahuje, zřejmě z úsporných důvodů, pouze přímé nadřazené a přímé podřazené koncepty a v rozhraní chybí úplné zobrazení cesty od kořene wordnetu k zobrazenému synsetu. I tak může strom být relativně dlouhý vzhledem k tomu, že u obecných hyperonym bývá seznam hyponym rozsáhlý.

Simple Search	Advanced Search	Synset Visualization	Help
---------------	-----------------	----------------------	------

Simple Search	Matching Lexical Entries	Selected LE	Related LE or Synset
---------------	--------------------------	-------------	----------------------

**Details of Related Lexical Entry (rad-n-2)**

General	Word Forms	Sense
Lemma: <b>rad</b>	Form	Definition: <b>wiel v.e. voertuig</b>
Part of Speech: <b>noun</b>	<b>rad</b>	<b>het singular</b>
Morpho-syntax: <b>n</b>	<b>raderen</b>	<b>de plural</b>
	<b>raden</b>	<b>de plural</b>

Semantics	Syntax	Relations
Countability: <b>count</b>	(No syntactics)	(No sense relations)
Reference: <b>common</b>		(No form relations)
Semantic Type: <b>artefact</b>		

**Examples**

Type/Phrase	Canonical Form
<b>freeCombination / np</b>	<b>de raderen van een treinstel/fiets</b>

**Hierarchy**

- schijf-n-1**
- rad-n-2 wiel-n-1**
- loopwiel-n-1**

Obrázek 4.3: Ukázka rozhraní Cornetto Demo: textová reprezentace dat

Z odkazů v hierarchii lze kliknutím na ikonu wordnetu u synsetu přejít do vizualizačního režimu, čímž se zobrazí grafické znázornění daného synsetu.

Modul vizualizace synsetů je v praxi pouze pseudomodul, jelikož jeho vyhledávání se od základního vyhledávání liší pouze tím, že vybírá jeden výsledek vyhledávání a rovnou jej zobrazí v grafické znázornění. Který výsledek se má vybrat, je možné zvolit při inicializaci hledání. Je tak eliminována nutnost zvolit synset, otevřít jeho detaily a kliknout na výše zmíněnou ikonu, aby se uživatel dostal na grafické znázornění daného synset, jedná se však pouze o zkratku v rozhraní, jež nezavádá nic nového.

Samotná vizualizace je realizovaná pomocí javascriptové knihovny d3 [BOH11] a umožňuje uživateli prohlížet všechny synsety svázané nějakým vztahem s vyhledaným synsetem.

vizualizuje  
vizuali-  
zační vi-  
zualizace,  
mwhahaha



Zobrazení rozlišuje syntaktické kategorie i sémantické vztahy barevně, přičemž vztahy jsou navíc ještě popsány slovně. Autoři použili rozšířený model vizualizace synsetů tak, že synset je představován uzlem, k němuž vede sémantický vztah, a z tohoto uzlu pak vedou nepojmenované hrany představující vazbu slovní formy na daný synset (tedy v zásadě vztah synonymie). Tento způsob je alternativní k zobrazení, v němž sémantické vztahy vedou k jednotlivým slovním formám a není tak na první pohled zřejmé, které navázané formy jsou součástí kterých synsetů. Zde použité zobrazení vhodně omezuje množství hran, které jsou nutné k vykreslení grafu, byť možná na úkor srozumitelnosti pro neznalého uživatele, jelikož body označující synset a hrany označující synonymii nejsou nijak označeny v grafu (pouze v legendě a při přejetí myši). Všechny uzly mají přiřazenou i vlastní legendu ve formě informační bubliny, která obsahuje například definici, příklady, slovní druh či identifikátory. Vizualizaci je možné kolečkem myši přibližovat a oddalovat a tažením myši se po zvětšeném grafu přesouvat. Funkčnost přibližování je možná poněkud diskutabilní, jelikož se při jejím použití nemění proporce zobrazovaných informací (cf. elektronické mapy na WWW, které při přiblížení sice zvětšují detail struktury, ale zachovávají velikost písmen v nápisech). Její smysl by v opačném případě tkvěl například v použití při vyhledání slov jako je *plant*<sup>2</sup>, které mají velké množství hyponym, a tudíž jejich graf je nepřehledný až do rozměrů naprosté nepoužitelnosti (obrázek 4.4 na straně 33). Ovládání klávesnicí možné není.

Rozhraní je neresponsivní, takže je na mobilním zařízení poněkud nepohodlné jej používat, byť to není nemožné. Šířka bloku s informacemi je natolik velká, že je nutné horizontálního rolování při čtení textu, což se považuje z hlediska použitelnosti webu za velmi negativní [; RH04]. Reprezentace grafem je vzhledem k ovládání, které používá, ještě hůře použitelná. Dotyk prstem do plochy s vykresleným grafem je totiž zároveň interpretován jako rolování celé stránky a zároveň jako tažení plátna s grafem do stran, které je běžně prováděno tažením myši po plátně. Přibližování a oddalování grafu, nikoliv celé stránky, v testovacím prostředí nebylo možné vůbec, ale vzhledem k vlastnostem této funkce popsaným výše to použitelnost nijak neomezuje. Co v mobilním testovacím prostředí v podstatě nefungovalo, byly informační bubliny u slov, jež se normálně zobrazují nad slovy; zde se zobrazovaly zcela mimo inkriminované slovo a částečně mimo zobrazovanou plochu.

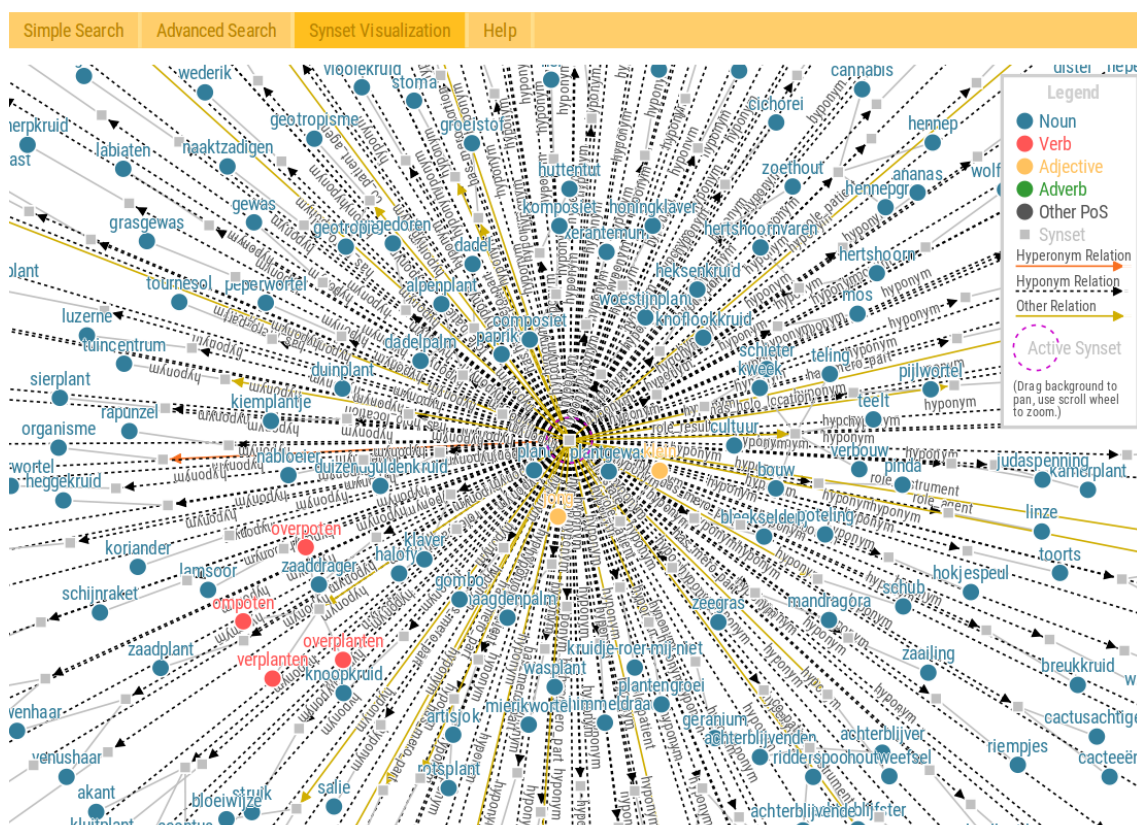
Oproti základnímu rozhraní WordNet Search 3.1 přináší toto rozhraní přehlednější textovou reprezentaci dat spojenou s vizualizací vztahů vyhledaného synsetu. Textové rozhraní však zobrazuje poněkud omezené množství informací z wordnetu a soustřeďuje se především na data ze slovníku Referentie Bestand Nederlands. Vztahy mezi slovy jsou zobrazovány pouze v grafické reprezentaci dat, což vzhledem k její nepřiliš vysoké použitelnosti na mobilních zařízeních s menší obrazovkou může být omezující. Rozhraní uchovává svůj stav podrobně v URL a umožňuje jej z ní plně obnovit.

## 4.4 WordVis

WordVis je rozhraní zaměřené na vizualizaci dat princetonského WordNetu grafem. Stavá se z vyhledávacího pole, levého sloupce s výběrem synsetů a plátnem, na němž je

---

<sup>2</sup>niz. rostlina



Obrázek 4.4: Ukázka rozhraní Cornetto Demo: ilustrace přepnutí grafické reprezentace hyponymy u slova **plant**

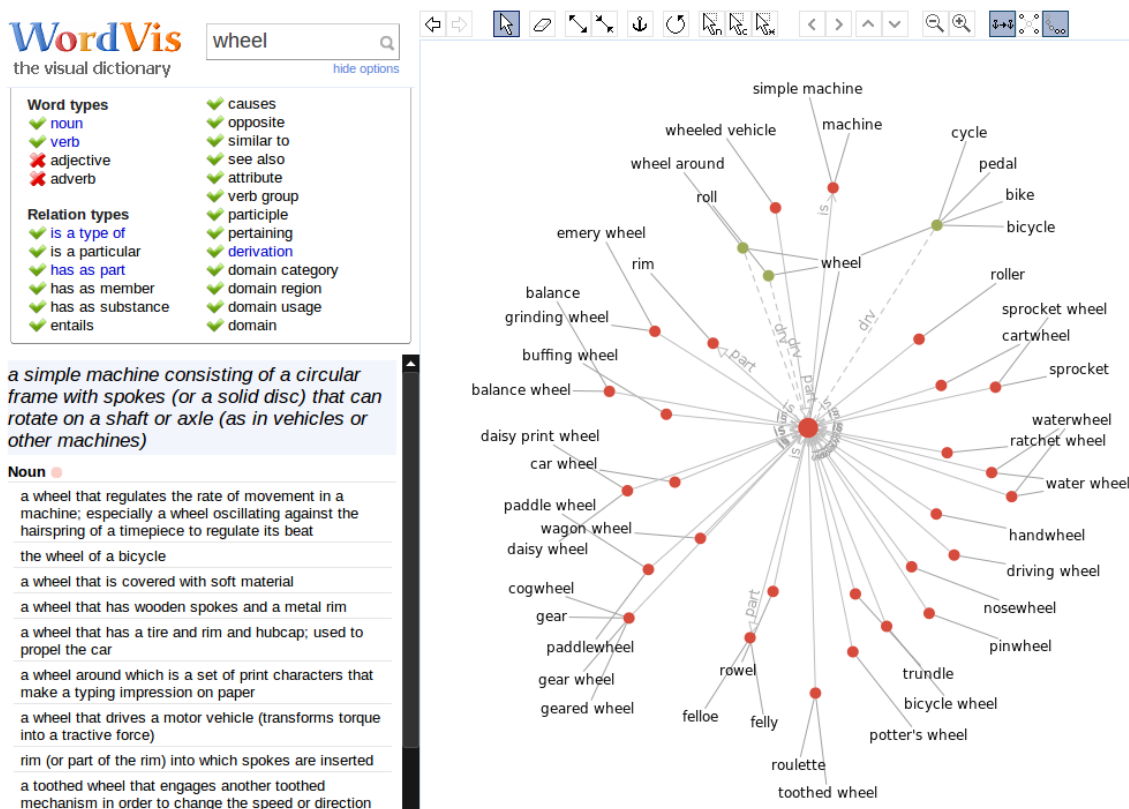
vykreslen graf vztahů zvoleného synsetu nebo slovní formy.

Ačkoliv to na první pohled uživateli nemusí být zřejmé, vizualizace funguje ve dvou režimech. Prvním je zobrazení slovní formy a synsetů, v nichž se tato slovní forma vyskytuje, druhé je zobrazení synsetu jako centrální jednotky a vztahů a slovních forem, které k danému synsetu patří. První zobrazení je užíváno například při prvotním zobrazení výsledků hledání. Vizualizace zobrazí ve středu grafu vyhledanou slovní formu a připojí k ní nepojmenovanými hranami synsety, jež danou slovní formu obsahují. Pokud pak uživatel zvolí kliknutím myši některý konkrétní synset, zobrazí se ve středu vizualizace jeho značka, k níž jsou připojeny pojmenovanými hranami představujícími sémantické vztahy další synsety. Stejně jako v prvním zobrazení, i v tomto se slovní formy náležející k určitému synsetu připojují nepojmenovanými hranami jako textové uzly. Pokud jedna slovní forma náleží k více synsetům (např. substantivum **bicycle** a sloveso **bicycle**), je v grafu její textový uzel pouze jednou a vedou od něj dvě nepojmenované hrany k náležitým synsetům.

Hrany mezi synsety jsou orientované (znázorněné jako šipky) a jejich k jejich pojmenování zvolil autor sémantické významy daných vztahů, tedy např. hyperonymie je značena

slovem *is*<sup>3</sup>; např. *apple tree is fruit tree*<sup>4</sup>.

Vyhledávací formulář umožňuje filtrování výsledků hledání podle slovních druhů a typů vztahu. Graf je navíc aktualizován v reálném čase podle toho, jak jsou podmínky filtrování uživatelem měněny. Nevýhodou však je absence funkcí *vybrat vše* a *nevybrat nic*, která je citelná zvláště v případě, že uživatel chce vybrat pouze jeden druh relace (kterých je mnoho, tudíž odebrání všech relací z výběru kromě jedné může být časově náročné). Hledání také nabízí funkci napovídání poté, co uživatel zadá několik znaků z počátku slova. To umožňuje vybrat hledané slovo z nabídky a ušetřit několik úhozů, což je zvláště užitečné u delších slov či pro uživatele, který nevyhledává ve svém rodném jazyce a není si jist pravopisem hledaného slova.



Obrázek 4.5: Ukázka rozhraní WordVis (po zvolení konkrétního vyhledaného synsetu)

Technologicky je vizualizace řešena javascriptovou knihovnou, jež vykresluje graf na HTML5 plátně [W3S]. Uspořádání prvků na plátně je řešeno modelováním fyzikálních vlastností našeho světa. Jednotlivé uzly na plátně mají zadefinováno, že se navzájem odpuzují (podobně jako elektrony), naopak vazby mezi nimi fungují jako pružiny, jež mají nějakou ideální délku, v níž se snaží setrvávat. Díky těmto dvěma soupeřícím silám jsou

<sup>3</sup>angl. *je*

<sup>4</sup>angl. jablň je ovocný strom

body na plátně rozmístěny tak, aby využívaly prostor co nejúčinněji. Hrany navíc mohou mít zadanou preferovanou orientaci, což umožňuje orientovat například hyperonymní synsety směrem nahoru, hyponymní směrem dolů etc. [Ver10] Vzhledem k tomu, že však zřejmě v prostředí neexistuje žádná penalizace za křížení hran, je relativně běžné, že se hrany překříží. To značně snižuje přehlednost výsledného grafu, vzhledem k tomu, že pak není jasné, zda jsou hrany překříženy z nějakého hlubšího důvodu (například jedna slovní forma náležející k více synsetům), či nikoliv. Knihovna vykreslující graf umožňuje uživateli také modifikovat tažením jednotlivých uzlů myší, prodlužovat či zkracovat hrany a podobně. V aplikaci pro zobrazení dat z WordNetu toto nehraje příliš zásadní roli a implementace této funkcionality je zřejmě dána tím, že knihovna je určena pro univerzálnější použití. [Ver10]

Rozhraní je neresponsivní a na mobilním zařízení je nutné k zajištění čitelnosti textů na stránce obsah přiblížit, což vede k nutnosti rolování jak vertikálnímu, tak horizontálnímu. Také není možné využít funkcionality přesouvání prvků na plátně, což ale při použití na vizualizaci dat z wordnetu není velkým omezením funkčnosti. Co se udržování stavu aplikace v URL týče, je implementováno pouze čtení parametru *q* (od *query*), zpětně do něj ale už zapisováno není. Odkazy na synsety na levé straně tento parametr obsahují, stejně tak jej lze zkopírovat přes kontextové menu pro každý uzel v rozhraní, takže teoreticky je možné obnovit kterýkoliv stav aplikace, byť dostupnost této funkcionality není příliš intuitivní.

Přínos tohoto rozhraní tkví především v relativně přehledné vizualizaci dat princeptonského WordNetu, nutno však podotknout, že pro některé své vlastnosti nemusí pro nezkušeného uživatele být zpočátku příliš intuitivní (např. zmíněné křížení hran).

Na knihovně, na níž je toto rozhraní postaveno, stojí ještě některá další rozhraní k princeptonskému WordNetu, například VisuWords<sup>5</sup> či Visual Thesaurus<sup>6</sup>. Ta nebyla do hodnocení v této práci zahrnuta, protože jsou funkčně podobná tomuto rozhraní.

## 4.5 sloWTool

Rozhraní sloWTool bylo vyvinuto pro potřeby slovinského wordnetu, jenž je založen na princeptonském WordNetu a vznikl skombinováním několika zdrojů, například Wikipedie, dvojjazyčných slovníků či paralelních korpusů. Je víceúčelovým nástrojem, který umožňuje textovou reprezentaci, vizualizaci a editaci dat z wordnetu. Tvůrcům sloužilo k revizím slovinského wordnetu po jeho rozšiřování automatickými nástroji. [FNE12] Cílem při vývoji tohoto rozhraní podle Fišer; Novak [FN11] bylo překonat nevýhody tehdejších dostupných rozhraní a vyvinout nástroj, který by mezi jiným umožňoval prohlížení i editaci, spolupráci mnoha autorů včetně anonymních editací (záměr tvůrců byl využít náhodných návštěvníků k opravování chyb, jež ve wordnetu naleznou) či možnost jednoduché registrace uživatelů. Mezi dalšími podmínkami byla možnost přidávání dalších wordnetů do systému a s tím spojená schopnost rozhraní zobrazovat vícejazyčná data. V neposlední

<sup>5</sup><http://www.visuwords.com/>, <https://www.linux.com/news/visuwords-wordnet-goes-graphical>

<sup>6</sup><https://www.visualthesaurus.com>

řadě se autoři v kontextu tehdejších nástrojů také snažili zaměřit na platformní nezávislost a přenositelnost rozhraní.

Rozložení stránky je vzdáleně podobné tomu u základního oficiálního rozhraní k princeptonskému WordNetu, a to v tom smyslu, že neobsahuje relativně rozšířený levý sloupec na výběr synsetů, ale jednotlivé významy, které jsou nalezeny po zadání hledané slovní formy do vyhledávacího pole, seskupuje do sekcí v hlavním bloku s textovou reprezentací dat. Vyhledávací pole podporuje napovídání existujících významů, což může usnadnit práci s rozhraním. V textové reprezentaci rozhraní zobrazuje zřejmě všechny dostupné informace o synsetech, tedy se chová podobně jako základní rozhraní princeptonského WordNetu, je-li nastaveno tak, aby nefiltrovalo žádné informace. U jednotlivých vztahů, v nichž je daný synset přítomen, pak je možné kliknutím otevřít synset nacházející se pomyslně na druhé straně daného vztahu (např. *bicykle* má meronymum *sedlo*, takže lze otevřít detail synsetu *sedlo*). To trpí stejným neduhem, jako základní rozhraní princeptonského WordNetu, to jest, že lze ve smyčce otevírat nadřazený a podřazený synset a stále se zanořovat do smyčky hlouběji. To je nejen nesmyslné, ale zároveň to v implementaci tohoto rozhraní postupně může začít zpomalovat rychlost reakcí prohlížeče pro nadměrné množství uzlů v DOM<sup>7</sup>.

Po levé straně se nachází lišta s ikonami odkazujícími na dalšími moduly, které se otevírají v emulacích nových oken (v témže panelu). Mezi tyto moduly patří mimo jiné i pokročilé hledání, vizualizace a nápověda.

Pokročilé hledání funguje podobně jako u ostatních rozhraní, tedy umožňuje používat zástupné znaky (\* a ?), filtrovat slovní druhy, nebo vyhledávat v jiných polích než jsou slovní formy patřící do synsetů (například v definicích či podle identifikátoru synsetu).

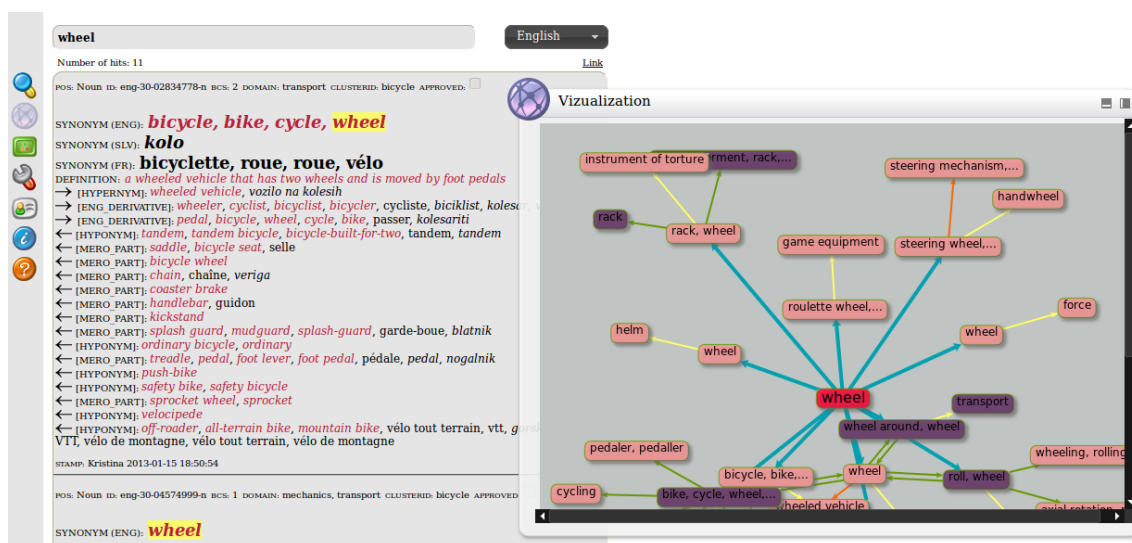
Vizualizace, modul z hlediska této práce nejpodstatnější, je určen k zobrazení grafické interpretace vztahů vyhledaného synsetu. Na rozdíl od ostatních rozhraní tato vizualizace zobrazuje všechny vyhledané synsety (s kořenem grafu označeným jako *search*<sup>8</sup>) a neumožňuje jejich filtrování. Také nepodporuje zřejmě žádnou formu interakce kromě přesouvání prvků na plátně a zvýraznění příslušného synsetu v hlavním bloku textové reprezentace poté, co je na něj (nebo jeho členskou slovní formu) ve vizualizaci kliknuto. Pokud uživatel potřebuje zobrazit vizualizaci jednoho konkrétního synsetu, je nucen použít pokročilé vyhledávání a vyhledat daný synset nejlépe podle jeho identifikátoru, který je vždy unikátní. Vizualizace je zatížena také dalšími problémy, jako jsou nedostatečné možnosti přizpůsobování velikosti zobrazovací plochy (zvětšování okna je podporováno, ale plátno s grafem zůstává konstantně velké), občasnou desynchronizaci obsahu vizualizace s výsledky hledání, náročností na uživatelské technické vybavení počítače (především výpočetní jednotku) a značnou nepřehledností způsobenou nedostatečně či nevhodně řešenou penalizací překrývání prvků na zobrazovací ploše.

Rozhraní je svými možnostmi zprostředkování informací z wordnetu poměrně inovativní, reálná použitelnost ovšem trpí zmíněnými nedostatky a odchyluje jej tím od původního záměru autorů, který minimálně zčásti zůstává nenaplněn. Je sice pravdou, že *s aplikací je možné pracovat v každém moderním prohlížeči, ať už na počítači, tabletu, či dokonce mobilním telefonu* [FN11], nutno ale podotknout, že rozhraní je zcela neresponsivní

---

<sup>7</sup>document object model

<sup>8</sup>hledání



Obrázek 4.6: Ukázka rozhraní sloWTool (s otevřenou grafickou vizualizací)

a jeho ovládací prvky jsou zcela nevhodné pro ovládání na menší obrazovce a dotykem.

Stav aplikace lze do jisté míry uložit pomocí odkazu *Link*, který vede na adresu, z níž lze obnovit hledané slovo (konfiguraci otevřených nástrojů však už nikoliv).

Navzdory všem nedostatkům této aplikace je dlužno uznat, že se svou univerzalitou a funkcionalitou značně přibližuje rozhraní, které je praktickým cílem i této práce.

SloWtool bylo vytvořeno pod licencí Creative Commons<sup>9</sup> a jeho zdrojový kód je dostupný na platformě pro aplikace s otevřeným zdrojem Launchpad<sup>10</sup>.

## 4.6 BabelNetXplorer

BabelNet je rozsáhlý projekt vícejazykové sémantické sítě, který čerpá data z více zdrojů. Záměrem autorů bylo při tvorbě této sémantické sítě eliminovat základní faktory definující nevýhody tehdejších (a potažmo i aktuálních) mezinárodních projektů zabývajících se sémantickými sítěmi. Těmi jsou manuální tvorba dat, které síť konstituují, a s tím související nerovnoměrnost množství dat přes jednotlivé jazyky. Jazyky s vysokou hustotou zdrojů, jakým je například angličtina, tak ve výsledku mají více dat i v sémantické síti. Autoři BabelNetu se pokusili tento problém překonat kombinací několika metod, jejichž společným jmenovatelem je automatizace. Informace o významech jsou v BabelNetu doplňovány z Wikipedie, která je podle autorů díky mnohačetným zásahům expertů z různých oborů ve výsledku přesným a informarčně bohatým zdrojem. Druhá důležitá metoda, zaměřující se především na nerovnoměrnost dat v různých jazycích, je automatický překlad zdrojů. [NP10]

<sup>9</sup><https://creativecommons.org/licenses/by-nc-sa/3.0/>

<sup>10</sup><https://launchpad.net/slowtool>

BabelNetXplorer je webové grafické rozhraní vytvořené pro vizualizaci dat z BabelNetu. [NP12] uvádějí, že rozhraní slouží k vizualizaci vztahů pro slova nalezená v BabelNetu a ilustrují vzhled rozhraní dvěma snímky obrazovky. V době vzniku této práce však rozhraní BabelNetXploreru vypadá výrazně odlišně, což je vzhledem k tomu, že od vzniku práce [NP12] uběhlo pět let, pochopitelné. V této práci bude z evidentních důvodů rozebrána použitelnost a funkcionality současného rozhraní.

Rozhraní obsahuje klasicky vyhledávací pole, vedle něhož se nacházejí rozbalovací menu, v nichž si uživatel může vybrat, ve kterém jazyce chce vyhledávat a, případně, do kterého jazyce chce slovo přeložit. Po úspěšném dokončení vyhledávání jsou uživatelům zobrazeny odkazy na jednotlivé synsety v seznamu, který není nepodobný ostatním rozhraním. Podstatným rozdílem však je, že se v něm zobrazují i ilustrační obrázky, které, byť nejsou vždy velmi informativní, mohou napomoci uživateli v orientaci, který synset jej zajímá.

V detailu synsetu, který se zobrazí po kliknutí na příslušný odkaz, je uživateli zobrazen seznam slovních forem, které k danému synsetu náleží, jeho definice (s možností zobrazit i jeho definice nejen z daného wordnetu, v němž uživatel vyhledává, ale i z Wikipedie a dalších zdrojů), jeho případný překlad a sémantické vztahy, do nichž tento synset náleží. K dispozici má uživatel i možnost zobrazit si daný synset paralelně v dalších jazycích pomocí nabídky pod vyhledávacím polem (viditelné na snímku obrazovky 4.7 na straně 39). Níže na stránce jsou uživatelům prezentovány informace z dalších zdrojů napojených na BabelNet, jako jsou obrázky, překlady, odkazy na Wikipedii, etc. a odkaz na vizuální reprezentaci sémantických vztahů otevřeného synsetu.

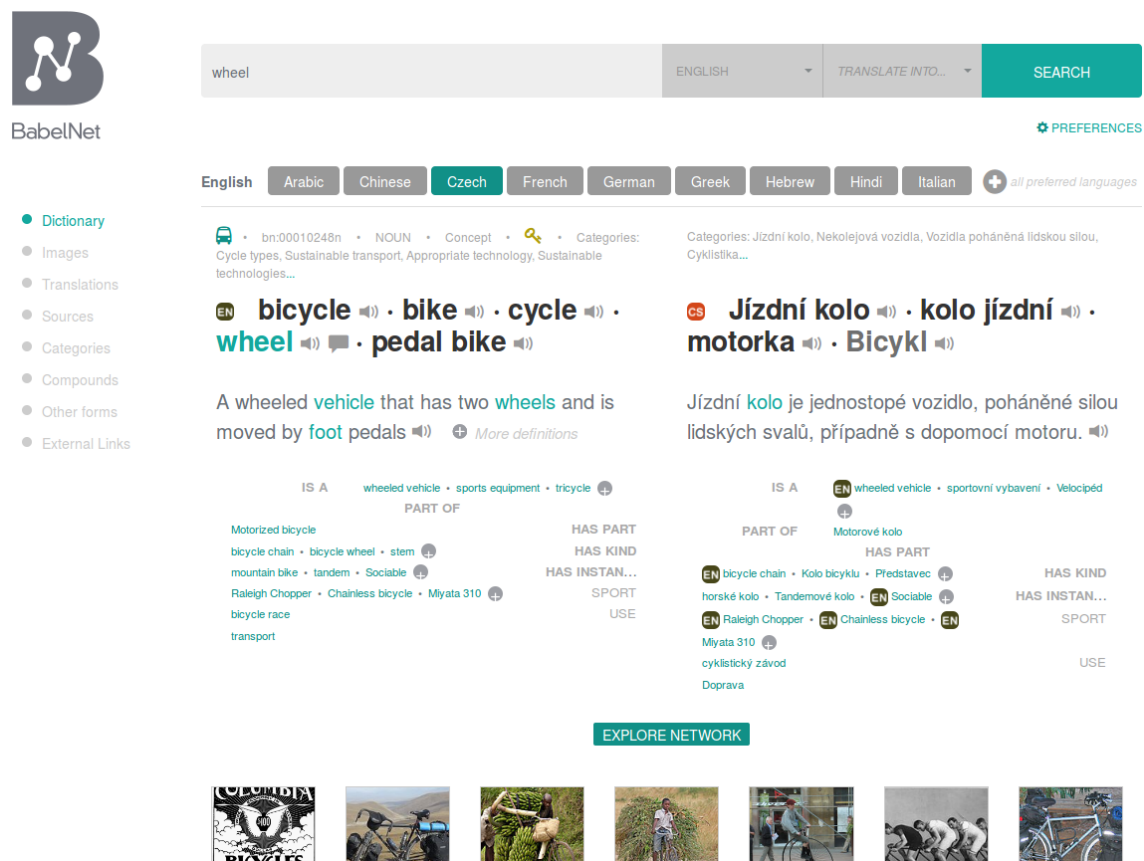
Vizuální reprezentace je řešena tradičním hvězdicovitým grafem, který má dva režimy. Jeden zobrazuje vedle textových názvů jednotlivých synsetů přítomných v grafu i jejich zástupné obrázky, druhý je čistě textový a, nutno podotknout, značně přehlednější. Uzly reprezentující synsety jsou provázány barevně odlišenými hranami, kde barvy značí druh vztahů, který dva synsety spojuje. Uzly jsou klikatelné, přičemž po kliknutí na některý z příbuzných synsetů se zobrazí tento synset a opět hvězdicovitě další synsety, s nimiž je zkoumaný synset provázán některým ze vztahů. Při najetí kurzorem myši na určitý synset se zobrazí jeho detail; tyto informační bubliny jsou však vázány na pozici kurzoru myši a nelze tak kurzorem najet do detailu tak, aby bylo možné kliknout na odkazy, které jsou v informační bublině obsaženy, a dostat se tak na textovou reprezentaci daného synsetu. Zdá se tedy, že není možné přejít z grafické reprezentace do textové.

Poněkud nešťastně je řešen design vizualizace, jelikož jednak není možné graf přibližovat a oddalovat, a jednak pokud uživatel nenajede na konkrétní synset kurzorem myši, graf se samovolně neustále otáčí, což ztěžuje orientaci v něm.

Rozhraní všeobecně responsivní, textová reprezentace je dobře použitelná i na mobilním rozhraní s malou obrazovkou. Grafická reprezentace je však omezena na větší obrazovky, jelikož v ní není možné graf posouvat po obrazovce, a tudíž jeho značná část (být se částečně přizpůsobuje zobrazovací ploše), zřejmě v závislosti na velikosti obrazovky zařízení, zůstává uživateli skryta.

V době vzniku této práce mělo rozhraní dvě verze, z nichž jedna byla označena jako *živá beta*, druhá jako *současná* (3.7), avšak při testování nebyly zjištěny zásadní rozdíly





The screenshot displays the BabelNet web interface. At the top, the BabelNet logo is on the left, and a search bar contains the word 'wheel'. Below the search bar, there are tabs for different languages: English, Arabic, Chinese, Czech (selected), French, German, Greek, Hebrew, Hindi, Italian, and a button for 'all preferred languages'. A 'SEARCH' button is on the right. Below the language tabs, the interface shows the entry for 'wheel' in English and its Czech equivalent 'Jízdní kolo'. The English entry includes a definition: 'A wheeled vehicle that has two wheels and is moved by foot pedals', and a list of synonyms: 'bicycle', 'bike', 'cycle', 'wheel', 'pedal bike'. The Czech entry includes a definition: 'Jízdní kolo je jednošlapé vozidlo, poháněné silou lidských svalů, případně s dopomocí motoru.' and a list of synonyms: 'Jízdní kolo', 'kolo jízdní', 'motorka', 'Bicykl'. Below the definitions, there are sections for 'IS A' (wheeled vehicle, sports equipment, tricycle) and 'PART OF' (Motorized bicycle, bicycle chain, bicycle wheel, stem, mountain bike, tandem, Sociable, Raleigh Chopper, Chainless bicycle, Miyata 310, bicycle race, transport). There are also sections for 'HAS PART', 'HAS KIND', 'HAS INSTAN...', 'SPORT', and 'USE'. At the bottom, there is an 'EXPLORE NETWORK' button and a row of seven small images showing various bicycles and people riding them.

Obrázek 4.7: Ukázka rozhraní BabelXplorer (detail synsetu v textové reprezentaci)

mezi těmito verzemi. Nutno ovšem podotknout, že na testovacím desktopovém prohlížeči vykazovala verze beta minoritní chyby v rozložení stránky.



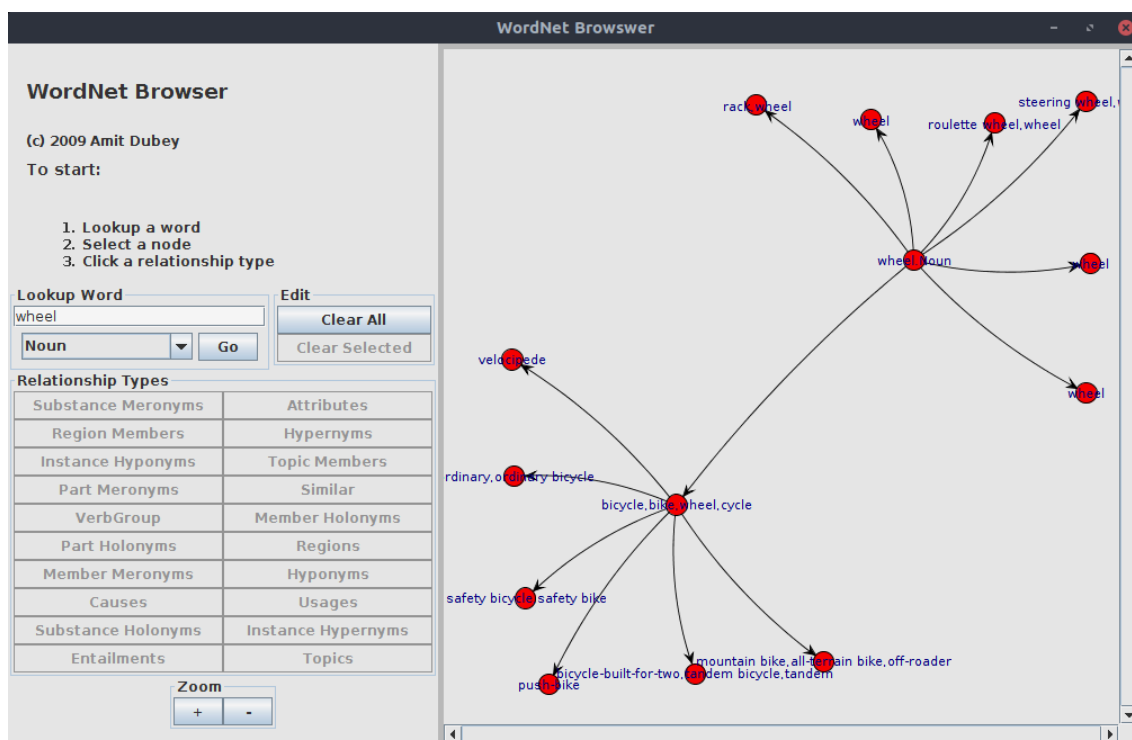
## Kapitola 5

# Vizualizace v aplikačním prostředí Java

Java je objektově orientovaný programovací jazyk, který je zaměřený na to, aby měl co nejméně závislostí na konkrétním operačním systému a technickém vybavení počítače, jak jen to je možné. To je výhodné zejména kvůli tzv. konceptu WORA (*write once, run anywhere*, tedy napiš jednou, spust' kdekoliv), protože to znamená, že skompilované programy napsané v Javě lze spustit na jakémkoliv stroji, který podporuje Javu. Takto skompilované programy se spouští v aplikačním prostředí zvaném Java Virtual Machine<sup>1</sup> (JVM), jež vytváří uniformní prostředí pro běh aplikací. Výhodou Javy tedy je velká přenositelnost programů v tomto jazyce napsaných, jelikož jednou skompilovaný kód lze spustit na různých operačních systémech a zařízeních. Nevýhodou je, že si uživatel, který chce program v Javě spustit, musí nainstalovat aplikační prostředí Javy (JVM).

Java je velmi oblíbená pro vývoj aplikací, které fungují podle modelu klient–server, což je uspořádání, v němž data má uložená centrální server, k němuž se připojují uživatelské klienty, odesílají mu své požadavky a uživatelům zobrazují vrácená data. Na podobném principu může fungovat i rozhraní pro wordnet, pokud jsou data wordnetu uložena na serveru.

Vizualizace vytvořené pro prostředí Java nemá příliš smysl hodnotit z hlediska responsiveness, jelikož a priori nejsou vytvářena pro mobilní zařízení (až na výjimky, které nebylo možné zhodnotit z důvodu jejich nedostupnosti v době vzniku této práce). Co však bráno v potaz být může je jejich schopnost přizpůsobit se velikosti obrazovky. Jakkoliv tento parametr může se zdát být samozřejmým, ukázalo se, že ne všechna rozhraní jsou na různé velikosti obrazovek osobních počítačů přizpůsobena.



Obrázek 5.1: Ukázka rozhraní wnbrowser

## 5.1 wnbrowser

Rozhraní wnbrowser<sup>2</sup> je určeno k prezentaci dat z princetonskému WordNetu, které pracuje pouze s grafovou grafickou reprezentací. Bylo vytvořeno pro reprezentaci dat z WordNetu ve verzi 3.0 a vyšší a vyžaduje lokální instalaci dat. Rozhraní je zřejmě svázáno se vznikem rumunského wordnetu [FN11]. Sestává z vyhledávacího pole, volby, mezi kterými syntaktickými kategoriemi se má vyhledávat, a selektoru na typy vazeb, jež mají být zobrazeny. Po úspěšném vyhledání konkrétního slova se zobrazí graf konceptuálně podobný grafu z rozhraní sloWTool, tedy ve středu je uzel reprezentující hledaný výraz, z něhož vedou hrany k jednotlivým synsetům, jež danou slovní formu obsahují.

Grafická reprezentace je interaktivní, tedy na ní lze zvolit, jaký druh sémantického vztahu se má zobrazit, a lze tak u každého uzlu postupně zobrazit všechny synsety, které jsou s ním provázány; toho lze docílit buď přes kontextové menu, nebo přes volby vztahů v levém sloupci rozhraní, v němž se mimo jiné nachází i vyhledávací pole. Rozhraní zobrazuje i detaily zvoleného synsetu (po kliknutí na daný synset), takže až na technické informace typu číslo významu a podobně je schopno zobrazovat všechna dostupná data.

Jakkoliv velikost okna s aplikací měnit lze, velikost plochy pro vykreslování grafu zůstává neměnné velikosti, lze tedy v terminologii webových aplikací říci, že je neresponsivní,

<sup>1</sup>virtuální stroj Javy

<sup>2</sup>sic erat scriptum

jelikož se nedokáže přizpůsobit velikosti obrazovky zařízení uživatele.

Aplikaci je možné používat bez připojení k Internetu, jelikož spoléhá na data WordNetu nainstalovaná lokálně.

Poněkud komicky působí fakt, že rozhraní má tři různé názvy: wnbrowser (hlavní nadpis stránky projektu), WordNet Browser (titulek okna aplikace) a wnbrowser (ostatní výskyty).

## 5.2 Treebolic

Treebolic je aplikace určená k zobrazování hierarchických dat v hyperbolické reprezentaci, která zajišťuje, že důležitá data v centru obrazovky jsou zobrazena uživateli ve větším měřítku, než data na okrajích grafu. Reprezentaci si lze představit jako plochu zobrazenou přes čočku.

Zobrazení používá model prezentující vše, co je nalezeno k hledanému slovu, tedy při úspěšném vyhledání výsledků se ve prostřed vizualizace zobrazí reprezentace vyhledávání, s níž jsou hranami provázány všechny nalezené synsety. Oproti ostatním zde popisovaným prostředím navíc seskupuje tyto synsety podle slovního druhu, tedy zavádí další metakategorii v zobrazení, což přispívá k přehlednosti zobrazení.

Co jí naopak ubírá, jsou poněkud kryptické ikony sémantických vztahů, jejichž význam je sice popsán na hraně, kde jsou dané ikony umístěny, popřípadě je možno jej odhalit pomocí nabídky *Info* v kontextovém menu po kliknutí pravým tlačítkem danou ikonu, ale při prvním setkání se toto řešení nezdá být příliš ergonomickým (mimo jiné proto, že duplikuje informace). Ne zcela evidentní jsou také číselné a procentuální údaje v místě uzlů se synsety. Uživatel se sice díky řešení, které používá konexe hranami ze synsetů k členským slovním formám, dozví, o který synset jde (díky oněm členským slovním formám), ale význam zmíněných údajů zůstává skryt. Výhodou je barevné kódování významů jednotlivých hran. Barvy jsou navíc editovatelné v nastavení, takže teoreticky rozhraní vyhoví i osobám se zhoršeným vnímáním barev.

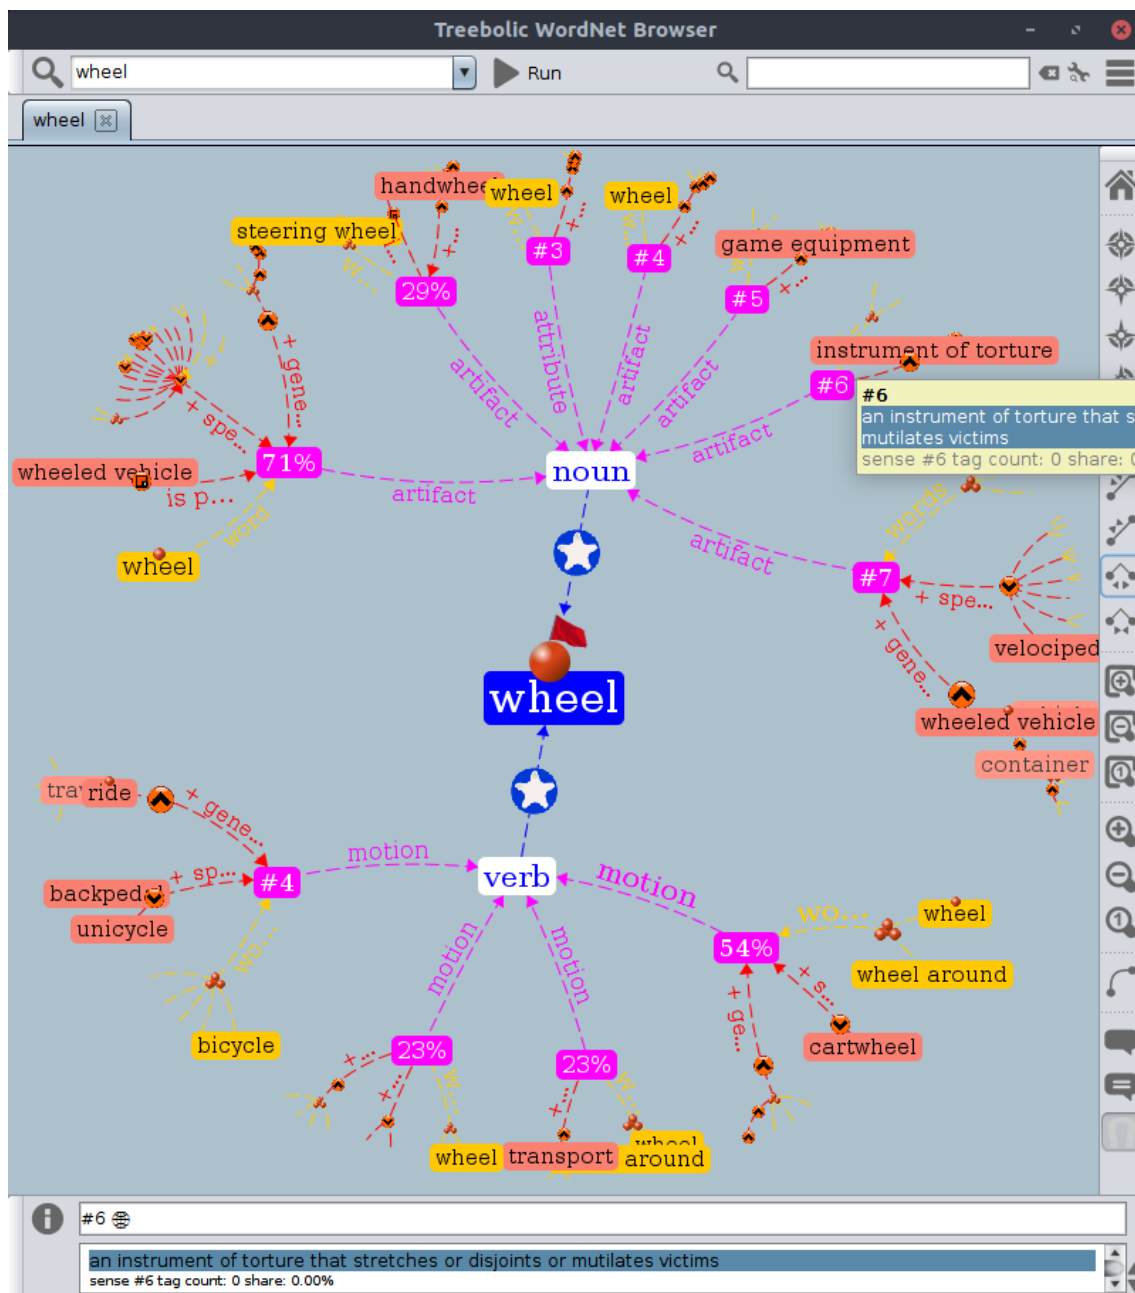
Aplikace byla vyvinuta i pro Android (jakkoliv v rámci této práce netestována), tudíž lze říci, že jistým zprostředkovaným způsobem splňuje požadavky na responsivitu.

Aplikaci je možné používat bez připojení k Internetu, jelikož spoléhá na data WordNetu nainstalovaná lokálně.

Teoretický přínos této implementace spočívá v pohledu na stratifikaci důležitosti vizualizovaných dat. Idea hyperbolického zobrazení, rozvinutá dále především v oblasti ovladatelnosti, by mohl být správným krokem prezentace dat ve větším množství, než je schopna obrazovka (a potažmo zorné pole) uživatele pojmout.

## 5.3 VisualBrowser

Verze aplikace VisualBrowser testovaná v rámci této práce neprokázala dostatečnou intuitivitu a funkčnost, aby její vlastnosti mohly být dále rozebrány.



Obrázek 5.2: Ukázka rozhraní Treebolic (se zobrazenou informační bublinou na synsetu)

## Kapitola 6

# Desktopové aplikace

Desktopové aplikace jsou takové aplikace, které jsou nativně určeny pro běh na operačním systému uživatelského počítače. Nativně spouštěná aplikace je, ať už přímo, či nepřímo, závislá na programových vlastnostech operačního systému daného stroje, stejně jako zprostředkovaně na jeho technickém vybavení. Přístupy k distribuci desktopových aplikací jsou v zásadě dva; první, z evidentních důvodů běžný především pro operační systém Windows, spočívá v distribuci již skompilovaných binárních souborů, které zajistí instalaci daného programu do systému a uživateli zbývá jen příslušný program spustit. Druhý způsob, běžný spíše pro různé linuxové distribuce, je založený na distribuci souborů obsahujících zdrojový kód programu, přičemž uživatel je nucen, má-li zájem program používat, si binární spustitelný soubor skompilovat. Druhý způsob pro programátora skýtá zásadní výhodu v tom, že se nemusí zajímat o prostředí, na němž bude koncový uživatel jeho program provozovat, protože kompilace programu pro všechny dostupné konfigurace (kombinace programového a technického vybavení koncového uživatele) je náročná na zdroje. [Eli15] Pro onoho koncového uživatele však slyne druhá varianta tou nevýhodou, že kompilace programového vybavení vyžaduje z jeho strany netriviální úsilí a znalosti o vlastním systému.

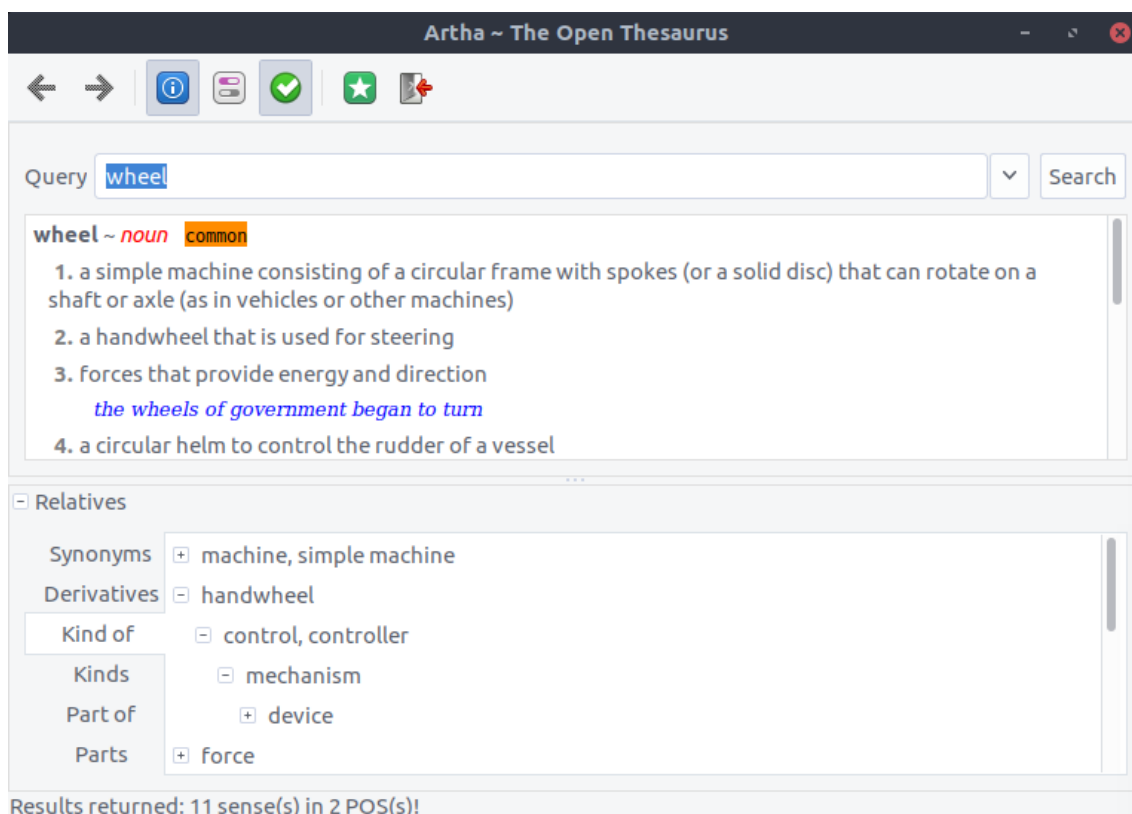
V rámci rozhraní určených pro zprostředkování dat z wordnetů jsou desktopové aplikace nejméně zastoupeny. Je tomu pravděpodobně proto, že jsou nejnáročnější na vývoj, zvláště mají-li být dostupné ze všech majoritních desktopových platforem. Dalším důvodem může být fakt, že často bývá zvolen model klient–server, pro který jsou vhodnější spíše aplikace v Javě [GM95, s. 13] a webová rozhraní.

### 6.1 Artha

Artha je multiplatformní thesaurus založený na WordNetu 3.0 [Ram12]. Grafické prostředí aplikace je vytvořeno v GTK<sup>1</sup>, takže umožňuje (minimálně na testovací konfiguraci, tedy operační systém Ubuntu 16.04) komfortní práci. Je možno ji nainstalovat z repozitářů (tedy nevyžaduje náročnou kompilaci), což je pro koncového uživatele velmi pozitivní. Dle

---

<sup>1</sup>multiplatformní soubor nástrojů pro tvorbu grafických rozhraní (<https://www.gtk.org/>)



Obrázek 6.1: Ukázka rozhraní aplikace Artha

dokumentace je k dispozici instalátor i na operační systém Windows<sup>2</sup>. O Apple macOS<sup>3</sup> se dokumentace nezmiňuje. Funguje bez připojení k Internetu a zobrazení je zaměřeno především na zobrazení významů synsetů (význam jsa reprezentován definicemi). Problémem je ukládání stavů aplikace, který se projevuje na nepříliš propracované funkcionalitě možnosti kroku zpět (na předchozí vyhledávání). Pokud například uživatel dvojklikne na slovo v definici, Artha se jej pokusí<sup>4</sup> přesměrovat na definici tohoto slova ve WordNetu, ale při kroku zpět už mu zobrazí slovo které hledal *před* slovem, z něhož se dostal na *současnou* definici. Oproti základnímu rozhraní WordNetu nabízí Artha větší pohodlí v podobě desktopové offline aplikace, což pro uživatele například znamená, že není při používání tohoto rozhraní závislý na připojení k Internetu.


Artha zobrazuje data čistě textově (ve smyslu, že nenabízí žádnou formu vizualizace), přičemž rozhraní dělí na dvě části, a to nalezené synsety a sémantické vztahy, které se k danému synsetu vážou (ilustrováno na snímku obrazovky 6.1 na straně 45).

<sup>2</sup><https://www.microsoft.com/en-us/windows/>

<sup>3</sup><https://www.apple.com/lae/macOS>

<sup>4</sup>selže, pokud uživatel vybere před dvojklikem více slov

## 6.2 GoldenDict



Obrázek 6.2: Ukázka rozhraní aplikace GoldenDict

Podobně jako Artha funguje GoldenDict, který, byvše univerzálnějším rozhraním pro více lexikografických zdrojů, byl testován jen ve své verzi pro WordNet. GoldenDict zobrazuje čistě textovou reprezentaci umožňující kliknutím zobrazit detaily jednotlivých synsetů. Slovníková data si obstarává aplikace sama, takže uživatel nemusí podstupovat instalaci dat princetonského WordNet (která může být netriviální, protože například pro Windows neposkytují oficiální webové stránky instalátor pro data WordNetu ve verzi 3). Zároveň však rozhraní umožňuje přidávat další slovníky a v základu umožňuje zobrazovat výsledku hledání z Wikipedie.

Rozhraní obsahuje levý sloupec pro zobrazování výsledků hledání a společně s hlavní plochou pro zobrazování detailů synsetu se chová podobně jako ostatní rozhraní (ilustrováno na snímku obrazovky 6.2 na straně 46). Aplikace udržuje historii hledání, umožňuje hledat slova z definic synsetů pomocí dvojkliku kurzorem myši a dává uživateli k dispozici relativně široké možnosti konfigurovatelnosti. Její rozhraní se dobře přizpůsobuje velikosti obrazovky (potažmo okna).

Grafické rozhraní aplikace GoldenDict je postaveno na Qt<sup>5</sup> a pro zobrazování dat z webu používá vykreslovací jádro WebKit<sup>6</sup>. [Isa13]

<sup>5</sup><https://www.qt.io/ui/>

<sup>6</sup><https://webkit.org/>

## Kapitola 7

# Shrnutí přehledu rozhraní a vyplývající závěry o vhodném rozhraní k sémantickým sítím

Rozhraní v přehledu prezentovaném v této práci byla hodnocena dle různých aspektů odpovídajícím účelu a provedení dané třídy rozhraní. Nejpodrobněji byla hodnocena webová rozhraní. U těch byla jako největší společný nedostatek identifikována nedostatečná responsivita, což vede k tomu, že uživatel dané rozhraní nemůže (nebo může velmi omezeně) používat na mobilním zařízení. To v době, kdy počet uživatelů přistupujících k webovým službám přes mobilní zařízení je vyšší než počet těch, kteří k nim přistupují pomocí klasických stolních počítačů [Hei16], aplikaci značně diskriminuje. Z podobného důvodu jsou v nevýhodě také rozhraní vytvořená pro aplikační prostředí Java a v ještě větší míře aplikace vytvořené přímo pro operační systémy stolních počítačů.

Aplikace vytvořené v Javě jsou sice teoreticky spustitelné i na některých mobilních operačních systémech (zejména Android<sup>1</sup>, u ostatních je podpora omezená či žádná<sup>2</sup>), prakticky je jejich použitelnost vzhledem k jejich designu grafického rozhraní omezena ale také výhradně na stolní počítače.

Pro některé aplikace vyvinuté v Javě byly vytvořeny tzv. aplety Java<sup>3</sup>, ale vzhledem k tomu, že některé silně rozšířené webové prohlížeče tento druh zásuvných modulů už vůbec nepodporují [Moz17], je jejich použití značně omezené a do budoucnosti lze předpokládat plošnou nepoužitelnost.

Rozhraní závislá na platformě (operačním systému, případně aplikačním rozhraní) mají navíc tu nevýhodu, že uživatel nalezená data nemůže jednoduše sdílet například se svými kolegy (od toho u webových rozhraní hodnocené reflektování stavu aplikace v adresním řádku prohlížeče).

---

<sup>1</sup><https://android.stackexchange.com/questions/63710/can-you-run-normal-java-programs-on-android>

<sup>2</sup><http://stackoverflow.com/questions/15501477/can-windows-phone-support-java>,  
<http://www.iphonefaq.org/archives/9731>, <http://stackoverflow.com/questions/1193524/can-we-run-java-applications-on-iphone> inter alia

<sup>3</sup><https://nlp.fi.muni.cz/projekty/visualbrowser/applet/index.html>



Z výše uvedeného je zřejmé, že je potřeba rozhraní, které bude použitelné univerzálně na všech platformách, a zároveň bude implementovat funkcionalitu všeobecně očekávanou u rozhraní pro wordnet. Tou je jednak textová prezentace dat a k ní dodatečná vizualizace ve formě grafu. Ideální rozhraní by také mělo splňovat designové požadavky moderních webových aplikací na přístupnost, tedy například nepředpokládat určitou velikost obrazovky uživatelského zařízení či ctít zásady vizuální přístupnosti (kontrastní barevné kódování, nepřekrývání textových prvků na obrazovce etc.). Je samozřejmě evidentní, že grafická prezentace dat nemůže být přizpůsobena velikosti obrazovky mobilního zařízení, mají-li být textové prvky čitelné a zároveň zachované rozložení prvků, může však být alespoň zajištěno, že funkcionalita posouvání zobrazovací plochy dotykem (u dotykových zařízení) není znemožněna funkcionalitou svázanou s prvky na obrazovce (jak tomu často bývá u implementací grafů synsetů, jejichž uzly je možné tažením myši přesouvat po zobrazovací ploše).

Kýžené rozhraní by také mělo splňovat požadavky na vizuální atraktivitu, aby se uživatelé cítili komfortně při práci s takovým rozhraním. Aspekty vizuálně komfortního rozhraní jsou do značné míry subjektivní, zdá se však, že uživatelé očekávají jistou prototypičnost designového konceptu od webové stránky s určitým účelem [Wal13; Tuc<sup>+</sup>12]. Studie [Tuc<sup>+</sup>12] také potvrzuje, že uživatelé pozitivně vnímají webové stránky s nízkou komplexitou, což může u implementace rozhraní wordnetu být problémem, jelikož takové rozhraní inherentně musí poskytovat velké množství informací. Cílem tedy je zobrazované informace vhodně strukturovat tak, aby uživatel měl pocit, že danou stránku zná a ví, kde na ní co najde, a necítil se zahlcen množstvím informací. Detaily designu takové aplikace jsou rozebrány v [zatím neexistující kapitole o tom, jak ty cypovinu píšu].

## Část III

# Praktická část: rozhraní k sémantické síti

## Kapitola 8

# Design rozhraní

8.1 Textová prezentace

8.2 Grafická prezentace

## Kapitola 9

# Použité technologie

9.1 HTML

9.2 CSS

9.3 JavaScript

9.4 JSON

# Bibliografie

- [ ] [online] [cit. 22. dub. 2017]. Dostupné z: <https://www.nngroup.com/articles/scrolling-and-scrollbars/>.
- [BOH11] BOSTOCK, Michael et al. D3 Data-Driven Documents. *IEEE Transactions on Visualization and Computer Graphics* [online]. 2011, roč. 17, č. 12, s. 2301–2309 [cit. 21. dub. 2017]. ISSN 1077-2626. Dostupné z DOI: 10.1109/TVCG.2011.185.
- [CQ69] COLLINS, Allan M; QUILLIAN, M Ross. Retrieval time from semantic memory. *Journal of verbal learning and verbal behavior*. 1969, roč. 8, č. 2, s. 240–247.
- [Cor] CORNETTO. *Getting started with the Cornetto demo*. Dostupné také z: <http://cornetto.clarin.inl.nl/help/GettingStarted.pdf>.
- [Cru86] CRUSE, D Alan. *Lexical semantics*. Cambridge University Press, 1986.
- [Eli15] ELIZABETH, Laura. *Should You Develop a Desktop or Web App?* [online]. 2015 [cit. 29. dub. 2017]. Dostupné z: <https://www.sitepoint.com/web-desktop-apps/>.
- [Fel05] FELLBAUM, Christiane. WordNet and wordnets. *Encyclopedia of Language and Linguistics*. Second. 2005, s. 665–670.
- [FJ65] FILLENBAUM, Samuel; JONES, Lyle V. Grammatical contingencies in word association. *Journal of Verbal Learning and Verbal Behavior*. 1965, roč. 4, č. 3, s. 248–255.
- [FBS04] FILLMORE, Charles J et al. FrameNet as a”Net”. In: *LREC*. 2004.
- [FN11] FIŠER, Darja; NOVAK, Jernej. Visualizing sloWNet. *Proceedings of the Electronic Lexicography in the 21st Century (eLex 2011)* [online]. 2011, s. 76–82 [cit. 25. dub. 2017].
- [FNE12] FIŠER, Darja et al. sloWNet 3.0: development, extension and cleaning. In: *GWC 2012 6th International Global Wordnet Conference* [online]. 2012, s. 113 [cit. 23. dub. 2017].
- [Gar82] GARRETT, Merrill F. Production of speech: Observations from normal and pathological language use. *Normality and pathology in cognitive functions*. 1982, s. 19–76.

- [Gar] GARSHOL, Lars Marius. Metadata? Thesauri? Taxonomies? Topic Maps! 2004—10—26)[2010-6—19] <http://www.ontopia.net/topicmaps/materials/tm-VS—thesauri.htm1>. Dostupné také z: <http://www.ontopia.net/topicmaps/materials/tm-vs-thesauri.html#N773>.
- [GM95] GOSLING, James; MCGILTON, Henry. The Java language environment. *Sun Microsystems Computer Company* [online]. 1995, roč. 2550 [cit. 29. dub. 2017].
- [Gro<sup>+</sup>14] GRONLI, Tor-Morten et al. Mobile application platform heterogeneity: Android vs Windows Phone vs iOS vs Firefox OS. In: *Advanced Information Networking and Applications (AINA), 2014 IEEE 28th International Conference on*. 2014, s. 635–641.
- [Hei16] HEISLER, Yoni. *Mobile internet usage surpasses desktop usage for the first time in history* [online]. 2016 [cit. 29. dub. 2017]. Dostupné z: <http://bgr.com/2016/11/02/internet-usage-desktop-vs-mobile/>.
- [HVR] HORÁK, Aleš et al. The development of a complex-structured lexicon based on WordNet. In: [online] [cit. 17. dub. 2017].
- [Isa13] ISAKOV, Konstantin. *GoldenDict - About* [online]. 2013 [cit. 29. dub. 2017]. Dostupné z: <http://goldendict.org/>.
- [KM02] KAMPS, Jaap; MARX, Maarten. Visualizing wordnet structure. In: *Proc. of the 1st International Conference on Global WordNet*. 2002, s. 182–186.
- [LL82] LEHRER, Adrienne; LEHRER, Keith. Antonymy. *Linguistics and philosophy*. 1982, roč. 5, č. 4, s. 483–501.
- [Lot03] LOTKO, Edvard. *Slovník lingvistických termínů pro filology*. 3. nezm. vyd. Olomouc: Univerzita Palackého v Olomouci, 2003. ISBN 80-244-0720-5.
- [MM05] MARTIN, Willy; MAKES, I. Referentie Bestand Nederlands. *Met medewerking van S. Bopp en M. Groot*. 2005.
- [Mil<sup>+</sup>90] MILLER, George A et al. Introduction to WordNet: An on-line lexical database. *International journal of lexicography*. 1990, roč. 3, č. 4, s. 235–244.
- [Moz17] MOZILLA FOUNDATION. *Why do Java, Silverlight, Adobe Acrobat and other plugins no longer work?* [online]. 2017 [cit. 29. dub. 2017]. Dostupné z: <https://support.mozilla.org/en-US/kb/npapi-plugins>.
- [NP10] NAVIGLI, Roberto; PONZETTO, Simone Paolo. BabelNet: Building a Very Large Multilingual Semantic Network. In: *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics* [online]. Uppsala, Sweden: Association for Computational Linguistics, 2010, s. 216–225 [cit. 27. dub. 2017]. ACL '10. Dostupné z: <http://dl.acm.org/citation.cfm?id=1858681.1858704>.

- [NP12] NAVIGLI, Roberto; PONZETTO, Simone Paolo. BabelNetXplorer: A Platform for Multilingual Lexical Knowledge Base Access and Exploration. In: *Proceedings of the 21st International Conference on World Wide Web* [online]. Lyon, France: ACM, 2012, s. 393–396 [cit. 27. dub. 2017]. WWW '12 Companion. ISBN 978-1-4503-1230-1. Dostupné z DOI: 10.1145/2187980.2188057.
- [Oxf03] OXFORD UNIVERSITY PRESS, Dorling Kindersley. *Illustrated Oxford dictionary*. Rev. ed. London, Oxford: Dorling Kindersley, 2003. ISBN 07-513-6436-3.
- [PŠ13] PALA, Karel; ŠEVEČEK, Pavel. Česká lexikální databáze typu WordNet. *Feedback*. 2013, roč. 48, č. A47.
- [PW06] PARADIS, Carita; WILLNERS, Caroline. Antonymy and negation—The boundedness hypothesis. *Journal of pragmatics*. 2006, roč. 38, č. 7, s. 1051–1080.
- [Pri] PRINCETON UNIVERSITY. *About WordNet* [online] [cit. 1. květ. 2017]. Dostupné z: <http://wordnet.princeton.edu>.
- [Ram12] RAMASWAMY, Sundaram. *Artha The Open Thesaurus* [online]. 2012 [cit. 29. dub. 2017]. Dostupné z: <http://artha.sourceforge.net/wiki/index.php/Home>.
- [RH04] RICHARDS, John T.; HANSON, Vicki L. Web accessibility: a broader view. In: *Proceedings of the 13th conference on World Wide Web - WWW '04* [online]. ACM Press, 2004 [cit. 21. dub. 2017]. Dostupné z DOI: 10.1145/988672.988683.
- [Ric08] RICHENS, Tom. Anomalies in the WordNet verb hierarchy. In: *Proceedings of the 22nd International Conference on Computational Linguistics-Volume 1* [online]. 2008, s. 729–736 [cit. 1. květ. 2017].
- [SDB07] SZYMANSKI, J et al. Cooperative editing approach for building wordnet database. In: *Proceedings of the XVI international conference on system science*. 2007, s. 448–457.
- [Thea] THE GLOBAL WORDNET ASSOCIATION. *GWA Base Concepts* [online]. Global WordNet Association [cit. 6. dub. 2017]. Dostupné z: <http://globalwordnet.org/gwa-base-concepts/>.
- [Theb] THE GLOBAL WORDNET ASSOCIATION. *Wordnets in the World* [online] [cit. 25. břez. 2017]. Dostupné z: <http://globalwordnet.org/wordnets-in-the-world/>.
- [Tou86] TOURETZKY, David S. *The mathematics of inheritance systems*. Morgan Kaufmann, 1986.
- [Tuc<sup>+</sup>12] TUCH, Alexandre N et al. The role of visual complexity and prototypicality regarding first impression of websites: Working towards understanding aesthetic judgments. *International Journal of Human-Computer Studies* [online]. 2012, roč. 70, č. 11, s. 794–811 [cit. 30. dub. 2017].
- [Ver10] VERCRUYSSSE, Steven. *About WordVis* [online]. 2010 [cit. 23. dub. 2017].

- [Vos98] VOSSEN, Piek. Introduction to eurowordnet. *Computers and the Humanities*. 1998, roč. 32, č. 2-3, s. 73–89.
- [Vos97] VOSSEN, Piek et al. EuroWordNet: a multilingual database for information retrieval. In: *Proceedings of the DELOS workshop on Cross-language Information Retrieval*. 1997, s. 5–7.
- [W3S] W3SCHOOLS. *HTML Canvas Reference* [online] [cit. 23. dub. 2017]. Dostupné z: [https://www.w3schools.com/tags/ref\\_canvas.asp](https://www.w3schools.com/tags/ref_canvas.asp).
- [Wal13] WALKER, Tommy. *Why “Simple” Websites Are Scientifically Better* [online]. 2013 [cit. 30. dub. 2017]. Dostupné z: <https://conversionxl.com/why-simple-websites-are-scientifically-better/>.
- [Wor] WORDNET REFERENCE MANUAL. *wngloss – glossary of terms used in WordNet system* [online] [cit. 1. květ. 2017]. Dostupné z: <https://wordnet.princeton.edu/wordnet/man/wngloss.7WN.html>.